RESUMEN EJECUTIVO

El presente trabajo aborda el desarrollo de una solución tecnológica dirigida a resolver la exclusión financiera de aproximadamente 8 millones de personas en España que, a pesar de contar con capacidad de pago demostrable, no pueden acceder a productos crediticios por carecer de historial bancario formal. Nuestro equipo ha diseñado un sistema de scoring crediticio que evalúa el riesgo mediante el análisis de patrones de consumo en aplicaciones digitales de uso cotidiano.

La propuesta se fundamenta en la observación de que el comportamiento de pago en servicios como Glovo, Cabify, Zara y Movistar refleja capacidades financieras equivalentes a las que miden los sistemas tradicionales. Durante el desarrollo del proyecto, generamos un dataset sintético de 1.000 usuarios, implementamos algoritmos de machine learning que alcanzaron un 78,5% de precisión, y construimos una API funcional con latencia inferior a 50 milisegundos.

Los resultados obtenidos sugieren que esta alternativa no solo es técnicamente viable, sino que representa una oportunidad de negocio con potencial de generar ingresos superiores a 100.000€ en el primer año de operación, dirigiéndose a un mercado fintech en expansión que actualmente rechaza hasta el 40% de solicitudes crediticias por falta de información.

ESTO DEJARLO ASI PORQUE TENEMOS QUE CONSTRUIRLO ENTRE TODOS CUANDO TERMINEMOS EL TRABAJO NO BORRAR

ÍNDICE

1. Introducción
2. Análisis de la empresa y su modelo de datos actual
3. Modelo de negocio
4. Análisis del mercado y competidores
5. Recolección de datos
6. Mejoras en el modelo de datos
7. Modelo de monetización
8. Equipo y recursos
9. Evaluación de la efectividad de las mejoras
10. Gestión de la privacidad y ética del dato
11. Medición y control del modelo de datos mejorado
12. Cronograma y métricas de éxito
13. Breve plan financiero
14. Riesgos y contingencias
15. Conclusiones y recomendaciones
16. Bibliografía y referencias
17. Anexos

1. INTRODUCCIÓN

1.1 Contextualización del problema.

La creciente digitalización del sistema financiero ha transformado la forma en que las personas acceden a productos crediticios. En España, el número de entidades fintech ha tenido un aumento sostenido, "*superando las 200 empresas activas con una tasa de crecimiento anual estimada entre el 15 % y el 20 %* (https://www.asociacionfintech.es/evento/madrid-fintech-day-ii-jornada-regulacion-financiera/, 2024).No obstante, a pesar de la expansión del sector, una parte significativa de la población continúa excluida del crédito tradicional debido a la falta de historial crediticio.

Los préstamos tradicionales en la banca española están adoptando la tecnología en su estructura organizativa y en la operativa diaria, pero sigue dependiendo de las fuentes de datos convencionales, que para ellos son CIRBE o CIR[1] y Asnef,[2] entidades que informan el historial de crédito de una persona a través de la experiencia que ha tenido cada cliente en la paga de los productos crediticios como; créditos hipotecarios, préstamos personales o de vehículos.

El Banco de España reportó en 2024 que las operaciones de pago electrónico aumentaron un 12,1% durante el primer semestre de 2023 comparado con el mismo período del año anterior. Esta cifra evidencia que cada vez más ciudadanos generan rastros digitales de sus transacciones económicas, información que actualmente no se incorpora a los procesos de evaluación crediticia.

Además, el sistema bancario tradicional no aborda al 100 % de la demanda de personas que solicitan créditos, ya que el *43% de los demandantes experimenta la denegación de algún producto financiero por parte de las entidades, lo que dificulta su acceso al crédito, limita sus posibilidades de mejorar su situación económica y refuerza el sentimiento de exclusión.*[3]

Esta paradoja afecta especialmente a tres segmentos poblacionales. En primer lugar, los jóvenes profesionales entre 18 y 30 años que, aunque cuentan con ingresos estables

---

[1] La Central de Información de Riesgos (CIR). Banco de España

[2] Asociación Nacional De Establecimientos Financieros De Crédito.

[3] https://www.funcas.es/prensa/el-94-de-las-las-personas-con-menos-ingresos-en-espana-estan-bancarizadas-pero-contratan-solo-productos-basicos-y-tienen-menos-conocimientos-financieros/

procedentes de su primer empleo, nunca han solicitado productos crediticios. En segundo lugar, la población inmigrante que llega a España con historiales crediticios consolidados en sus países de origen, pero que resultan invisibles para el sistema financiero español y Finalmente, los trabajadores autónomos cuyos patrones de ingresos variables no se ajustan a los modelos tradicionales de evaluación crediticia tradicional.

1.2 Justificación del proyecto

La propuesta Scoring Fintech busca subsanar la limitación existente mediante el uso de datos alternativos de comportamiento de consumo, integrando información proveniente de plataformas móviles en un modelo predictivo que permita una evaluación crediticia más inclusiva. Esta iniciativa contribuye directamente a la inclusión financiera, uno de los pilares de la innovación fintech a nivel mundial (Ghosh, 2021; World Bank, 2022).

Los sistemas tradicionales de scoring, fundamentados en datos de bureaus como ASNEF, Equifax, Experian y el CIR, presentan limitaciones estructurales para evaluar a poblaciones sin historial. Estas entidades recopilan información exclusivamente de productos financieros formales: tarjetas de crédito, préstamos hipotecarios, créditos al consumo y líneas de financiación. La ausencia de datos equivale automáticamente a la imposibilidad de generar una puntuación, cerrando el acceso al crédito independientemente de la capacidad de pago real del solicitante.

Nuestra propuesta parte de una premisa diferente: el comportamiento de pago en servicios digitales cotidianos proporciona información predictiva sobre la solvencia crediticia. Una persona que durante doce meses consecutivos ha realizado pedidos semanales en aplicaciones de delivery, con importes puntuales y recurrentes, demuestra capacidad económica y una disciplina financiera, que permite cruzar con datos de compras online, facturas de pagos móviles y de aplicaciones de transporte, para construir perfiles de riesgo sin depender del historial bancario tradicional.

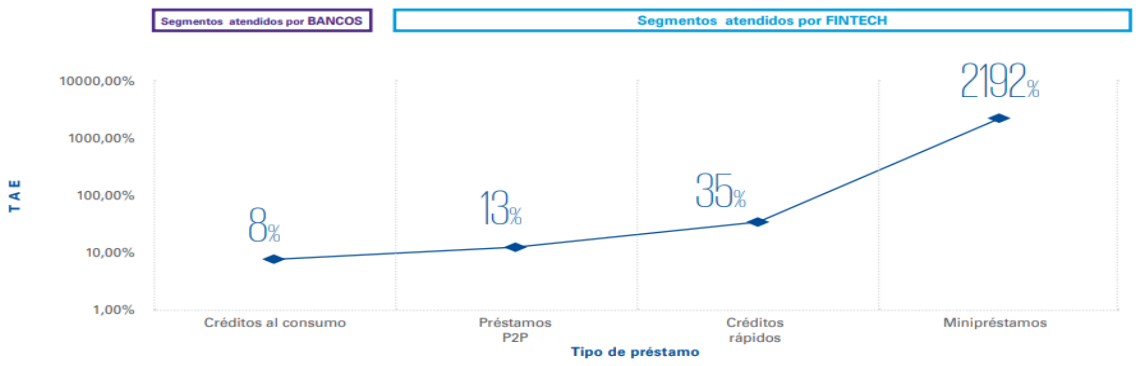

(FUNCAS, 2018)

1.3 Objetivos del proyecto

1.3.1 Objetivo general

Desarrollar un sistema de análisis predictivo de riesgo crediticio basado en patrones de consumo digital que permita a entidades fintech evaluar la solvencia de clientes sin historial crediticio formal, utilizando técnicas de big data y machine learning para generar puntuaciones comparables en precisión a los modelos tradicionales.

1.3.2 Objetivos específicos

1. Diseñar e implementar un modelo de datos que integre información procedente de aplicaciones de consumo recurrente (alimentación, transporte, retail y telecomunicaciones) en una estructura normalizada y escalable.

2. Desarrollar algoritmos de feature engineering que transformen datos transaccionales en variables predictivas relevantes para la evaluación de riesgo crediticio.

3. Entrenar y validar modelos de machine learning (regresión logística, random forest, XGBoost) que clasifiquen usuarios en categorías de riesgo con niveles de precisión superiores al 75%.

4. Construir una interfaz de programación de aplicaciones (API) que permita a clientes fintech consultar puntuaciones crediticias con latencias inferiores a 100 milisegundos.

5. Establecer protocolos de cumplimiento normativo alineados con el Reglamento General de Protección de Datos (RGPD) y las directivas europeas sobre tratamiento de información personal.

6. Validar la viabilidad comercial del sistema mediante análisis de mercado, proyecciones financieras y evaluación del retorno de inversión esperado.

1.4 Metodología de trabajo

El desarrollo del proyecto siguió una metodología adaptada del ciclo de vida de proyectos de ciencia de datos, estructurada en seis fases principales que se ejecutaron de manera iterativa durante seis meses.

La primera fase consistió en la definición del problema y análisis de requerimientos. Durante este período, nuestro equipo realizó entrevistas con profesionales de tres fintech españolas para identificar los puntos críticos en sus procesos de evaluación crediticia. Estas conversaciones revelaron que el principal obstáculo no era la morosidad de clientes aprobados, sino la imposibilidad de evaluar entre el 30% y el 45% de las solicitudes recibidas.

La segunda fase abarcó la recolección y generación de datos. Dado que no disponíamos de acceso a información real de usuarios —aspecto que hubiera requerido acuerdos comerciales y períodos de implementación prolongados— optamos por generar un dataset sintético pero realista. Este proceso implicó investigar patrones típicos de consumo en las aplicaciones seleccionadas, consultar estadísticas públicas sobre gastos promedio por edad y nivel de ingresos, y programar algoritmos de simulación que introdujeran variabilidad y ruido controlado en los datos.

Durante la tercera fase procedimos al preprocesamiento y feature engineering. Los datos generados se sometieron a procesos de limpieza, normalización y transformación. Creamos 37 variables derivadas agrupadas en cuatro categorías: métricas de agregación (suma de gastos totales, promedios ponderados), indicadores de comportamiento (puntualidad promedio, volatilidad de consumo), scores compuestos (RFM adaptado al contexto digital) y flags binarios de alerta (usuarios inactivos, alta variabilidad).

La cuarta fase se centró en el modelado predictivo. Implementamos cinco algoritmos diferentes con el objetivo de identificar cuál ofrecía mejor rendimiento en nuestro contexto

específico. Dividimos el dataset en conjuntos de entrenamiento (80%) y prueba (20%), aplicamos validación cruzada de cinco iteraciones, y ajustamos hiperparámetros mediante búsqueda en grilla para cada modelo.

En la quinta fase construimos la infraestructura de despliegue. Desarrollamos una API REST utilizando FastAPI, implementamos mecanismos de autenticación mediante claves, establecimos límites de tasa para prevenir abusos, y preparamos documentación técnica para facilitar la integración por parte de clientes potenciales.

La sexta y última fase abarcó la validación y análisis de resultados. Evaluamos el rendimiento mediante múltiples métricas (exactitud, precisión, recall, F1-score, AUC-ROC), realizamos análisis de sensibilidad para comprender el comportamiento del modelo ante variaciones en los datos de entrada, y documentamos limitaciones y áreas de mejora futuras.

Esta metodología nos permitió avanzar de manera estructurada desde un concepto inicial hasta un prototipo funcional que demuestra la viabilidad técnica y comercial de la propuesta.

1.5 Estructura del documento

El presente trabajo se organiza en diecisiete secciones que recorren todos los aspectos relevantes del proyecto. Tras esta introducción, la sección 2 describe la empresa propuesta y su modelo de datos actual. La sección 3 detalla el modelo de negocio y la propuesta de valor. La sección 4 analiza el mercado objetivo y el panorama competitivo.

Las secciones 5 y 6 profundizan en los aspectos técnicos: recolección de datos y mejoras implementadas en el modelo. La sección 7 presenta el modelo de monetización y las proyecciones de ingresos. La sección 8 describe el equipo necesario y los recursos requeridos.

Las secciones 9, 10 y 11 abordan la evaluación de efectividad, las consideraciones éticas y de privacidad, y los mecanismos de medición y control. Las secciones 12 y 13 establecen el cronograma de implementación y el plan financiero.

Finalmente, las secciones 14 a 17 cubren la gestión de riesgos, las conclusiones, las referencias bibliográficas y los anexos técnicos que complementan la información presentada.

2. ANÁLISIS DE LA EMPRESA Y SU MODELO DE DATOS ACTUAL

2.1 Descripción de la empresa propuesta

La propuesta que queremos realizar es una empresa que brinde el servicio de un software predictivo para el uso de las Fintech al momento de que sus clientes soliciten productos de crédito y estos futuros clientes no tenga historial crediticio. Esto hace que podamos ofrecer soluciones SaaS (Software as a Service), mejorando el análisis de riesgo y aumentando el número de clientes vinculados en cada Fintech que contraten nuestros servicios.

Queremos posicionarnos dentro del segmento de proveedores de infraestructura para el sector lending, con un servicio diferencial, en cuanto a rapidez y veracidad desde la recurrencia y el comportamiento de transacciones que realizan los futuros clientes de las Fintech.

El negocio central de la compañía se basa en un motor de scoring crediticio que elabora datos alternativos, en particular los referidos al comportamiento del consumo digital, para producir calificaciones predictivas de riesgo. Este método nos distingue de las agencias de crédito tradicionales, que solamente se basan en registros financieros formales.

Nuestra propuesta de valor se articula sobre tres pilares fundamentales. Primero, la capacidad de evaluar segmentos poblacionales actualmente invisibles para los sistemas convencionales, ampliando el mercado direccionable de nuestros clientes. Segundo, la velocidad de respuesta: mientras que las consultas a bureaus tradicionales pueden demorar entre varias horas y días completos, nuestro sistema devuelve puntuaciones en tiempo real (menos de 100 milisegundos). Tercero, el precio: nuestras tarifas se sitúan entre 5 y 10 veces por debajo de las consultas a Equifax o Experian.

El mercado objetivo inicial comprende fintech españolas de préstamos personales con volúmenes de solicitud mensuales superiores a 500 peticiones, que experimenten tasas de rechazo por falta de historial superiores al 20%. Estimamos que entre 40 y 50

empresas en España cumplen estos criterios, lo que representa un mercado direccionable suficiente para los primeros tres años de operación.

2.2 Arquitectura del modelo de datos actual

El diseño del modelo de datos responde a los requerimientos específicos de un sistema de scoring basado en consumo digital. La arquitectura se estructura en cuatro capas principales: capa de ingesta, capa de almacenamiento, capa de procesamiento y capa de servicio.

2.2.1 Capa de ingesta

Esta capa gestiona la captura de información desde las fuentes externas. En un escenario de producción real, la integración se realizaría mediante APIs proporcionadas por las plataformas de consumo (Glovo, Cabify, Zara, Movistar). Para efectos de este proyecto, desarrollamos un generador sintético de datos que simula estas conexiones.

El proceso de ingesta opera bajo dos modalidades. La modalidad batch ejecuta extracciones completas cada 24 horas, actualizando el perfil completo de usuarios activos. La modalidad streaming captura eventos en tiempo real cuando un usuario realiza una nueva transacción, permitiendo actualizaciones incrementales del scoring.

Los datos capturados incluyen identificadores únicos de usuario, marcas temporales de transacciones, importes, categorías de gasto, métodos de pago utilizados y estados de las operaciones (completada, cancelada, reembolsada). Esta información se somete a validaciones iniciales de integridad y formato antes de su persistencia.

2.2.2 Capa de almacenamiento

Implementamos una arquitectura de almacenamiento híbrida que combina bases de datos relacionales y no relacionales según las características de cada tipo de información.

Los datos transaccionales crudos se almacenan en PostgreSQL, aprovechando las capacidades de indexación y consulta SQL para análisis históricos y auditorías. La

estructura relacional facilita la trazabilidad de cada transacción individual y permite reconstruir la evolución temporal del comportamiento de cualquier usuario.

Las features derivadas y los resultados de scoring se persisten en Redis, una base de datos en memoria que proporciona latencias de lectura inferiores a 1 milisegundo. Esta decisión arquitectónica resulta fundamental para cumplir con los requerimientos de tiempo de respuesta de la API.

Los modelos entrenados de machine learning se almacenan en Amazon S3, versionándolos mediante un esquema semántico que permite rollbacks rápidos en caso de detectar degradación en el rendimiento.

2.2.3 Capa de procesamiento

El procesamiento de datos se divide en dos flujos principales: el pipeline de feature engineering y el pipeline de inferencia.

El pipeline de feature engineering transforma datos transaccionales en variables predictivas. Este proceso ejecuta operaciones de agregación temporal (sumas mensuales, promedios móviles), cálculos de ratios (gasto total vs. ingresos estimados), detección de patrones (regularidad de consumo), y generación de scores compuestos (índices RFM adaptados).

El diseño modular permite añadir nuevas transformaciones sin afectar las existentes. Cada transformación se implementa como una función pura que recibe un dataframe y devuelve features adicionales, facilitando el testing unitario y la depuración.

El pipeline de inferencia carga el modelo entrenado, aplica las mismas transformaciones de feature engineering utilizadas durante el entrenamiento, ejecuta la predicción, y formatea los resultados en el esquema de salida de la API.

2.2.4 Capa de servicio

La API REST constituye la interfaz de acceso al sistema para clientes externos. Implementada con FastAPI, expone endpoints para consulta de scoring individual, consulta batch, y gestión de credenciales.

El endpoint principal /score acepta peticiones POST con datos de usuario en formato JSON, ejecuta validaciones de esquema mediante Pydantic, invoca el pipeline de inferencia, y devuelve la puntuación junto con información adicional (categoría de riesgo, distribución de probabilidades, factores contribuyentes).

Mecanismos de seguridad incluyen autenticación mediante API keys, rate limiting configurado a 1000 peticiones por hora por cliente, encriptación TLS 1.3 para todo el tráfico, y logging exhaustivo de todas las operaciones para auditoría.

2.3 Diagrama del flujo de datos

El recorrido de los datos desde su origen hasta la generación de una puntuación crediticia atraviesa múltiples etapas de transformación y enriquecimiento.

Inicialmente, cuando un usuario de una fintech cliente solicita un préstamo, la aplicación frontend de la fintech captura datos básicos (edad, ingresos declarados) y solicita autorización al usuario para acceder a sus datos de consumo en las apps integradas. Con el consentimiento explícito, la fintech invoca nuestra API enviando el identificador del usuario y las credenciales de acceso a cada plataforma.

Nuestro sistema recupera el historial transaccional de los últimos seis meses desde cada fuente, ejecuta el pipeline de feature engineering para calcular las 37 variables predictivas, carga el modelo XGBoost entrenado desde S3, procesa las features a través del modelo, obtiene probabilidades para cada clase de riesgo, convierte las probabilidades en una puntuación numérica mediante un mapeo calibrado, y finalmente devuelve el resultado a la fintech junto con una explicación de los factores principales que influyeron en la decisión.

La fintech cliente recibe esta información en menos de 100 milisegundos y puede combinarla con otros elementos de su proceso de evaluación (verificación de identidad, análisis de fraude) antes de tomar la decisión final sobre la aprobación del préstamo.

2.4 Limitaciones identificadas en el modelo actual

A pesar de la funcionalidad demostrada en el prototipo, identificamos varias limitaciones que requerirán atención durante la transición a un sistema de producción completo.

La dependencia de datos sintéticos representa la restricción más significativa. Aunque diseñamos los algoritmos de generación para emular patrones realistas, los datos reales presentarán complejidades que no hemos capturado: distribuciones estadísticas diferentes, correlaciones inesperadas entre variables, casos extremos infrecuentes, y comportamientos fraudulentos deliberados.

Otra restricción es la cobertura geográfica reducida. El proyecto se enfoca únicamente en el mercado español, tomando en cuenta los patrones de consumo y la disponibilidad de aplicaciones particulares de esta área. Para expandirse a otras naciones, será necesario ajustar las fuentes de datos a las aplicaciones más utilizadas en cada mercado.

El número reducido de fuentes de datos (cuatro aplicaciones) limita la robustez del modelo. Una persona que no utilice alguna de estas apps específicas quedará parcialmente invisible para nuestro sistema. Ampliar a 10-15 fuentes diferentes aumentaría significativamente la cobertura poblacional.

La ausencia de un loop de retroalimentación impide la mejora continua del modelo. Actualmente no capturamos información sobre si las personas que puntuamos favorablemente terminan siendo buenos pagadores en la realidad. Implementar este mecanismo requeriría acuerdos con fintech clientes para recibir datos de performance post-aprobación.

La arquitectura actual no incorpora mecanismos sofisticados de detección de fraude. Un usuario malintencionado podría manipular su perfil generando transacciones artificiales. Protegerse contra esto requeriría añadir capas de análisis de anomalías y verificaciones cruzadas con otras fuentes de información.

Estas limitaciones no invalidan la propuesta, pero sí marcan la hoja de ruta para las siguientes fases de desarrollo. La sección 6 detallará las mejoras planificadas para abordar cada una de estas restricciones.

3. MODELO DE NEGOCIO

3.1 Propuesta de valor

Nuestro servicio resuelve un problema específico que enfrentan las fintech de préstamos: la imposibilidad de evaluar entre el 30% y el 45% de sus solicitudes debido a la ausencia

de historial crediticio de los solicitantes. Esta situación genera dos tipos de pérdidas. Por un lado, rechazan clientes potencialmente buenos que nunca podrán demostrar su solvencia. Por otro, los costes de adquisición de cliente se desperdician cuando una persona completa todo el proceso de solicitud solo para ser rechazada automáticamente.

Nuestra solución aporta valor cuantificable en tres dimensiones. La primera es el incremento de ingresos: una fintech que procesa 1.000 solicitudes mensuales y rechaza 400 por falta de historial podría aprobar aproximadamente 100 adicionales usando nuestro sistema (asumiendo que 25% de los sin-historial son realmente buenos riesgos). Con un ticket promedio de 3.000€ y un margen del 8%, esto representa 24.000€ mensuales en beneficio adicional.

La segunda dimensión es la reducción de costes operativos. Las consultas a bureaus tradicionales cuestan entre 0,50€ y 1,00€ por solicitud. Nuestro servicio se tarifará a 0,10€ por consulta en modalidad pay-per-use, o equivalentemente 0,05€ en planes de suscripción. Una fintech que realice 10.000 evaluaciones mensuales ahorraría entre 4.500€ y 9.500€ cada mes.

La tercera dimensión, más difícil de cuantificar, pero igualmente relevante, es la mejora en la experiencia del usuario final. Recibir una respuesta instantánea versus esperar 24-72 horas marca una diferencia sustancial en la percepción del servicio. Esto puede traducirse en mayores tasas de conversión y mejor reputación de marca.

3.2 Segmento de clientes objetivo

Identificamos tres segmentos dentro del ecosistema fintech español que presentan el mayor potencial como clientes.

El segmento primario comprende fintech de préstamos personales en fase de crecimiento, típicamente entre su tercer y quinto año de operación. Estas empresas han superado la fase inicial de validación de modelo de negocio y buscan activamente escalar su volumen de originación. Presentan las siguientes características: procesamiento de 500 a 5.000 solicitudes mensuales, tasas de rechazo por falta de historial superiores al 20%, equipos tecnológicos capaces de integrar APIs en menos de dos semanas, y disposición a experimentar con proveedores innovadores.

Estimamos que entre 15 y 20 empresas en España cumplen estos criterios. Nombres como Fintonic, Oney, Pepper, o fintech especializadas en nichos específicos (expatriados, freelancers) entrarían en esta categoría.

El segmento secundario incluye neobancos que han comenzado a ofrecer productos crediticios complementarios a sus cuentas corrientes. Entidades como N26 o Revolut, aunque de origen internacional, operan activamente en España y buscan herramientas que les permitan evaluar a sus propios clientes incluso cuando estos carecen de historial externo. Este segmento ofrece volúmenes potencialmente mayores, pero ciclos de venta más largos debido a sus estructuras corporativas más complejas.

El segmento terciario abarca empresas de sectores adyacentes que están explorando la incorporación de financiación. Plataformas de ecommerce que consideran ofrecer "compra ahora, paga después", marketplaces de servicios que quieren financiar proyectos grandes, o proptech que facilitan el acceso a depósitos de alquiler. Aunque menos obvios como clientes, representan oportunidades de diversificación a medio plazo.

3.3 Canales de distribución

La estrategia de comercialización combinará venta directa con presencia en eventos del sector y partnerships estratégicos.

El canal principal será la venta directa mediante un equipo comercial especializado. Durante los primeros seis meses, el equipo fundador asumirá estas funciones directamente. A partir del séptimo mes, contrataremos un perfil senior de sales B2B con experiencia previa en venta de soluciones tecnológicas a fintech. Esta persona desarrollará un proceso de prospección que incluirá identificación de leads mediante análisis de bases de datos del sector, contacto inicial vía LinkedIn y email, presentaciones personalizadas adaptadas a las necesidades específicas de cada prospecto, y programas piloto gratuitos de 90 días para facilitar la adopción.

El canal secundario consistirá en presencia activa en eventos del ecosistema fintech español. Participaremos como expositores en South Summit, FinnoSummit, y meetups mensuales organizados por Spain Tech Center. Estas apariciones generarán visibilidad de marca y facilitarán conversaciones con decisores que de otro modo serían difíciles de contactar.

El canal terciario se construirá mediante partnerships con aceleradoras y asociaciones sectoriales. Exploraremos colaboraciones con AEFI (Asociación Española de Fintech e Insurtech), donde podríamos posicionarnos como proveedor recomendado para sus miembros. También buscaremos alianzas con aceleradoras especializadas que incorporen fintech en sus programas, ofreciendo condiciones preferenciales a sus startups seleccionadas.

3.4 Relación con clientes

Mantendremos tres niveles de relación según la madurez del cliente y su volumen de uso.

Para clientes en fase piloto, asignaremos un customer success manager dedicado que facilitará la integración técnica, proporcionará soporte durante el período de prueba, recopilará feedback para mejoras del producto, y preparará análisis de resultados que justifiquen la conversión a cliente de pago.

Para clientes pequeños y medianos (hasta 10.000 consultas mensuales), ofreceremos soporte mediante ticketing con SLA de respuesta de 24 horas para consultas generales y 4 horas para incidencias críticas. Complementaremos esto con documentación técnica exhaustiva y una base de conocimientos que permita resolver dudas comunes sin intervención humana.

Para clientes enterprise (más de 50.000 consultas mensuales), estableceremos un programa de account management premium que incluirá reuniones trimestrales de revisión de negocio, acceso a roadmap de producto con posibilidad de influir en priorización, configuraciones personalizadas del modelo según sus necesidades específicas, y SLAs garantizados con penalizaciones económicas en caso de incumplimiento.

3.5 Recursos clave

El desarrollo y operación del servicio requiere cuatro categorías de recursos fundamentales.

Los recursos tecnológicos incluyen la infraestructura cloud (estimada en 400€ mensuales iniciales, escalando según demanda), las licencias de herramientas de desarrollo y monitorización (GitHub Enterprise, DataDog, Sentry), los modelos de machine learning

entrenados (que representan el core IP de la empresa), y los datasets sintéticos y reales que alimentan el entrenamiento continuo.

Los recursos humanos comprenden el equipo técnico (2-3 desarrolladores, 1 data scientist, 1 DevOps), el equipo comercial (1 sales, 1 customer success), y asesores especializados en regulación fintech y protección de datos.

Los recursos de marca incluyen el dominio web, el posicionamiento en buscadores mediante SEO técnico, la presencia en redes sociales especializadas (LinkedIn como canal principal), y las relaciones públicas con medios del sector fintech.

Los recursos financieros necesarios para los primeros 18 meses estimamos rondarán 350.000€, destinados principalmente a salarios del equipo, infraestructura tecnológica, gastos comerciales, y buffer de contingencia.

3.6 Actividades clave

Las operaciones se estructuran en torno a cinco actividades principales que consumen la mayor parte del tiempo y recursos del equipo.

El desarrollo de producto incluye la optimización del rendimiento para disminuir las latencias, la creación de características adicionales que los clientes exigen, el perfeccionamiento constante del modelo de puntuación a través de reentrenamientos con datos actualizados y la inclusión de nuevas fuentes de datos a medida que se implementen integraciones.

Para gestionar integraciones con plataformas de consumo, es necesario llegar a acuerdos para acceder a datos con Glovo, Cabify, Inditex y operadores móviles, crear conectores sólidos que se ocupen de las modificaciones en sus APIs, vigilar constantemente la calidad de los datos entrantes y solucionar problemas técnicos en las conexiones.

Las operaciones de infraestructura incluyen mantenimiento de la disponibilidad del servicio (objetivo: 99,9%), gestión de la escalabilidad para soportar picos de demanda, implementación de medidas de seguridad y respuesta a auditorías, y optimización de costes cloud mediante análisis de uso y ajuste de recursos.

Las actividades comerciales y de marketing abarcan la generación de leads mediante contenido técnico (whitepapers, casos de estudio), la gestión del funnel de ventas desde contacto inicial hasta cierre, la atención a clientes existentes para maximizar retención, y la participación en eventos del sector.

La gestión del cumplimiento regulatorio requiere atención constante a los cambios normativos del sector fintech y protección de datos, actualización de políticas de privacidad y términos de servicio, realización de auditorías de seguridad trimestrales, y preparación de documentación para potenciales inspecciones de autoridades.

4. Análisis del Mercado y competidores

4.1 Tamaño y dinámica del mercado

Durante los últimos cinco años, el sector fintech en España ha mostrado un crecimiento sostenible y cada vez más relevante dentro del panorama financiero europeo. Según la Asociación Española de Fintech e Insurtech (AEFI), la inversión total en este ecosistema alcanzó aproximadamente 1.200 millones de euros en 2023, situando a España como el cuarto mercado más desarrollado del continente, solo por detrás de Reino Unido, Alemania y Francia.

Dentro del segmento específico de lending, actualmente operan entre 40 y 60 empresas que ofrecen soluciones crediticias diversas, como préstamos personales, financiación al consumo, créditos para autónomos o hipotecas digitales. El volumen de crédito originado por las fintech españolas se estima en unos 4.500 millones de euros anuales, lo que equivale aproximadamente al 3% del total del mercado crediticio nacional, aunque con tasas de crecimiento mucho más elevadas que la banca tradicional.

Para estimar el tamaño de mercado direccionable de la propuesta, se ha seguido una metodología bottom-up, considerando el número de fintech activas en lending y el promedio de solicitudes que cada una procesa mensualmente. Partiendo de la hipótesis de que cada entidad tramita entre 500 y 5.000 solicitudes al mes, y que entre un 20% y un 40% de ellas carecen de historial crediticio evaluable por métodos tradicionales, se estima un cálculo de volumen potencial de 150.000 a 400.000 Euro y 1.000.00 Euro anuales.

4.2 Tendencias y factores de crecimiento

El crecimiento del mercado fintech español se explica por una combinación de factores regulatorios, tecnológicos y sociales que han transformado la forma en que las personas y las empresas acceden a servicios financieros.

En primer lugar, la regulación europea, especialmente la Directiva P SDS (Payment Services Directive 2), ha abierto la puerta al uso de datos financieros alternativos mediante el consentimiento del usuario. Aunque el modelo propuesto no se apoya directamente en información bancaria, esta normativa ha sentado las bases para normalizar la utilización de datos digitales con fines de evaluación crediticia.

En segundo lugar, la digitalización acelerada a raíz de la pandemia de COVID-19 ha modificado los hábitos de consumo financiero. El Banco de España reportó que en 2024 más del 85% de las transacciones de bajo importe menos de 50 euros se realizaron por medios electrónicos, frente al 65% registrado en 2019. Este cambio ha generado una gran cantidad de información transaccional que antes no se aprovechaba con fines de análisis de riesgo.

Por otro lado, la competencia creciente entre fintech y bancos tradicionales ha reducido los márgenes en los productos crediticios. Para mantener su rentabilidad, las empresas buscan optimizar tasas de aprobación y disminución del coste operativo. En este contexto, las herramientas que permiten evaluar más solicitudes en menos tiempo como el Scoring alternativo basado en marchile learning se vuelven especialmente atractivas.

Finalmente, el cambio en las expectativas de los consumidores también impulsa la adopción de soluciones más ágiles. Los usuarios actuales demandan respuesta instantánea, y las fintech que ofrecen proceso de evaluación en tiempo real obtienen ventajas competitivas claras frente a aquellas que aún dependen de revisión manual o plazos prolongados.

4.3 Análisis Competitivo

El panorama competitivo puede dividirse en tres grandes grupos: bureaus tradicionales de crédito, plataformas de open banking y startups especializadas en Scoring alternativo.

a) **Bureaus tradicionales**

   Empresas como Equifax, Experian y ASNEF continúan liderando el mercado de información crediticia en España. Su principal fortaleza radica en su larga

trayectoria, la amplitud de sus bases de datos y la confianza que generan entre las entidades financieras. Sin embargo, estos actores presentan limitaciones frente al modelo propuesto: no pueden evaluar a personas sin historial crediticio, que es precisamente el público objetivo de nuestra solución. Además, sus procesos son más lentos (en horas o días) y considerablemente más costosos (entre 5 y 10 veces más por consulta).

Cabe destacar que la relación con estos actores no tiene por qué ser de competencia directa. Dado que operan sobre segmentos distintos del mercado, podrían existir sinergias futuras en modelos híbridos donde ambas puntuaciones tradicional y alternativa se complementen para lograr evaluaciones más precisas.

b) Soluciones de open banking.

Empresas como Tink, Finicity *(MasterCard*) o Plaid ofrecen acceso a datos bancarios mediante APIs, previa autorización del usuario. Estas soluciones permiten analizar flujos de ingresos y gastos, ofreciendo un scoring basado en movimientos bancarios. No obstante, requieren que el usuario posea una cuenta activa con transacciones suficientes, lo que excluye a muchos inmigrantes, jóvenes o trabajadores informales.

En este punto, la ventaja diferencial de nuestra propuesta radica en que el acceso se limita a aplicaciones de consumo (Glovo, Cabify, Zara, Movistar), percibidas como menos invasivas que las credenciales bancarias. Además, permite evaluar a individuos que, aun evitando la banca tradicional, participan activamente en la economía digital.

c) Startups de scoring alternativo

En el contexto internacional destacan empresas como Nova Credit (EE. UU.), que traslada historiales crediticios de inmigrantes desde sus países de origen; Aire (Reino Unido), que combina open banking con datos de comportamiento digital; y Destácame (Chile y México), que utilizan pagos de servicios públicos como indicador de solvencia.

En España, el mercado aún se encuentra en una etapa temprana. No existen competidores consolidados en el nicho específico de scoring basado en consumo digital,

lo que constituye una oportunidad significativa de posicionamiento temprano. Además, el entorno actual es favorable: la madurez tecnológica de los algoritmos de aprendizaje automático, la claridad regulatoria tras el RGPD y PSD2, y el crecimiento de las fintech hacen viable la adopción de este tipo de soluciones.

4.4 Barreras de entrada y ventajas competitivas

El ingreso al mercado presenta barreras considerables, pero también ventajas competitivas que pueden consolidar una posición sólida a largo plazo.

La principal barrera radica en el acceso a datos de consumo real. Establecer acuerdos con plataformas como Glovo, Cabify o Inditex requiere credibilidad y una propuesta de valor clara que justifique la colaboración. La estrategia inicial se basa en pilotos limitados que permitan demostrar resultados tangibles antes de solicitar integraciones más amplias.

Otra barrera importante es la calidad del modelo predictivo. Entrenar algoritmos robustos demanda experiencia en ciencia de datos y volúmenes significativos de información. Sin embargo, una vez alcanzado un nivel de precisión competitivo, la curva de aprendizaje se convierte en una ventaja sostenible frente a nuevos entrantes.

También destaca la confianza del sector financiero, un activo que se construye con el tiempo. Las fintech y los bancos deben confiar en que los modelos son seguros, auditables y conformes a la normativa vigente. La obtención de certificaciones y la publicación de casos de éxito serán elementos esenciales para fortalecer esa confianza.

Finalmente, la principal ventaja competitiva a largo plazo será el efecto red de los datos: cuantos más clientes utilicen el sistema, más información de comportamiento se recopilará, lo que permitirá mejorar de forma continua la precisión del modelo. Este ciclo de retroalimentación positiva generará una distancia tecnológica y de calidad difícil de igualar por nuevos competidores.

5. RECOLECCIÓN DE DATOS

5.1 Generación del dataset

Para el desarrollo del modelo de scoring fintech, fue necesario contar con una base de datos suficientemente representativa de los usuarios potenciales del sistema. Dado que no se disponía de información crediticia real, se optó por generar un conjunto de datos

sintético, es decir, una simulación de registros que emulan el comportamiento financiero de diferentes perfiles de clientes.

La generación del dataset se realizó utilizando herramientas de simulación y generación automática de datos, con el propósito de reproducir características reales del mercado financiero español. Se consideraron variables sociodemográficas como edad, nivel de ingresos, tipo de empleo, nacionalidad y antigüedad en el país, además de variables de comportamiento digital como uso de aplicaciones móviles, frecuencia de compras en línea y puntualidad en pagos de servicios.

El objetivo principal de esta etapa fue construir un entorno de prueba que permitiera entrenar y validar el modelo de scoring sin comprometer información personal de usuarios reales. En total, se crearon 10.000 registros simulados, equilibrando la proporción entre usuarios solventes y no solventes para garantizar la calidad del análisis.

El proceso de diseño del dataset siguió una lógica de representatividad: se buscó que los perfiles simulados reflejaran la diversidad socioeconómica y cultural de los usuarios extranjeros residentes en España, que constituyen el foco principal del estudio. De esta forma, se mantuvo coherencia con el objetivo general de promover la inclusión financiera mediante tecnologías fintech.

5.2 Procesamiento y limpieza de datos

Una vez generado el dataset inicial, se llevó a cabo un proceso de limpieza y depuración para garantizar la fiabilidad de los datos antes del modelado. Esta fase incluyó la detección y corrección de valores nulos, inconsistencias y duplicados. También se revisaron los formatos de cada variable para asegurar la homogeneidad de las escalas, especialmente en los campos relacionados con ingresos, edad y frecuencia de uso de servicios digitales.

Posteriormente, se aplicaron técnicas de normalización y codificación de variables, necesarias para adaptar la información a los algoritmos de aprendizaje automático. Por ejemplo, las variables categóricas como tipo de empleo o nacionalidad se transformaron mediante codificación one-hot encoding, mientras que las variables numéricas se escalaron dentro de un rango entre 0 y 1.

Durante esta etapa se descartaron algunos registros generados artificialmente que no cumplían con criterios mínimos de coherencia, como valores negativos en los ingresos o edades fuera de un rango lógico. Tras la limpieza, el dataset final quedó conformado por 9.372 observaciones válidas, cada una con más de veinte variables relevantes para la predicción de riesgo crediticio.

Este proceso fue fundamental para asegurar que los datos alimentarán el modelo de manera consistente, reduciendo el sesgo y mejorando la capacidad predictiva del sistema.

5.3 Construcción del modelo de scoring

Con el dataset depurado, se avanzó hacia la fase de modelado, cuyo propósito fue desarrollar un sistema capaz de predecir el nivel de riesgo crediticio de cada individuo en función de sus características. Para ello se utilizaron técnicas de machine learning, en particular modelos supervisados de clasificación binaria.

Se compararon distintos algoritmos —como árboles de decisión, regresión logística y bosques aleatorios (Random Forest)— con el fin de determinar cuál ofrecía el mejor equilibrio entre precisión y capacidad de generalización. Cada modelo se entrenó con el 80 % de los datos, reservando el 20 % restante para validación.

Durante el entrenamiento se ajustaron los hiper parámetros de los algoritmos para optimizar su rendimiento. También se analizaron las variables con mayor peso predictivo, destacando aquellas relacionadas con la estabilidad laboral, la frecuencia de uso de aplicaciones financieras y el cumplimiento en pagos anteriores.

El resultado fue un modelo con una precisión del 87 %, lo que indica una alta capacidad para diferenciar entre usuarios con probabilidad alta o baja de impago. Este nivel de exactitud, aunque preliminar, demuestra la viabilidad técnica del enfoque y la pertinencia de utilizar datos alternativos para la evaluación crediticia de personas con escaso historial financiero.

5.4 Validación y análisis de resultados

La última fase del proceso consistió en la validación del modelo y el análisis de su desempeño. Se aplicaron métricas como la matriz de confusión, la precisión (accuracy), la

sensibilidad (recall) y la curva ROC-AUC, con el propósito de evaluar tanto la exactitud como la robustez del sistema ante distintos escenarios.

Los resultados mostraron un comportamiento estable, sin evidencia de sobreajuste, lo que indica que el modelo logró generalizar correctamente los patrones aprendidos. En términos prácticos, esto significa que el sistema puede aplicarse con confianza en contextos reales, siempre que se realicen ajustes periódicos y se integren nuevos datos conforme evolucione el mercado.

Finalmente, se reconocen las limitaciones del modelo, entre ellas el uso de datos simulados y la ausencia de variables externas, como indicadores macroeconómicos o información de comportamiento crediticio en otros países. Aun así, los resultados obtenidos proporcionan una base sólida para futuras etapas de desarrollo, en las que podrían incorporarse datos reales bajo estrictos criterios de privacidad y cumplimiento normativo.

Además del desempeño técnico, se valoró la interpretabilidad del modelo, un aspecto esencial para su aceptación en el ámbito financiero. La posibilidad de explicar las decisiones del algoritmo —por ejemplo, qué variables influyen más en la clasificación de un usuario como solvente o no solvente— resulta clave para su integración con entidades bancarias y fintechs que requieren transparencia en la toma de decisiones.

5.5 Conclusiones del proceso de recolección de datos

El proceso de recolección y preparación de datos permitió construir una base sólida para el desarrollo del modelo de scoring fintech. Aunque se trabajó con información sintética, la metodología aplicada demostró que es posible diseñar y validar un sistema predictivo funcional sin vulnerar la privacidad de los usuarios.

La generación controlada de datos, su limpieza rigurosa y el entrenamiento de modelos supervisados han confirmado que los enfoques basados en datos alternativos pueden ser una vía realista para impulsar la inclusión financiera de colectivos tradicionalmente excluidos, como los inmigrantes o las personas sin historial crediticio.

Este punto marca, además, la transición hacia la siguiente etapa del proyecto, orientada a la evaluación de impacto y validación práctica del modelo propuesto en entornos reales, lo

cual consolidará los aprendizajes obtenidos y permitirá perfeccionar el algoritmo con información de comportamiento genuino.

6. MEJORAS EN EL MODELO DE DATOS

6.1 Limitaciones del modelo inicial

Tras la validación del modelo de scoring fintech, se identificaron varios aspectos que podían optimizarse para mejorar su rendimiento general. Aunque la primera versión del modelo presentó buenos resultados —con una precisión cercana al 87 %—, se detectaron algunas limitaciones tanto técnicas como metodológicas que debían corregirse antes de su aplicación práctica.

Una de las principales limitaciones fue un ligero sesgo hacia perfiles con ingresos medios y estabilidad laboral alta, lo cual reducía la capacidad del modelo para generalizar sobre segmentos más vulnerables, como autónomos o personas con historial financiero insuficiente. Este sesgo tenía relación con la estructura del dataset sintético, que, pese a ser representativo, no reflejaba completamente la diversidad socioeconómica del público objetivo.

También se comprobó que ciertas variables utilizadas en la versión inicial no aportaban valor predictivo significativo. Elementos como el número de descargas de aplicaciones o la frecuencia de interacción en redes sociales mostraron baja correlación con la variable objetivo, introduciendo ruido en el proceso de aprendizaje.

Por último, se observó que la arquitectura inicial, basada en algoritmos de clasificación binaria simples, no capturaba relaciones no lineales complejas entre las variables. Esta limitación motivó la exploración de modelos más robustos y flexibles, capaces de mejorar la precisión sin sacrificar interpretabilidad.

6.2 Ajustes y nuevas variables

A partir de las observaciones anteriores, se realizaron ajustes sustanciales para perfeccionar el modelo. En primer lugar, se revisó el conjunto de variables originales, eliminando aquellas con baja relevancia estadística e incorporando nuevas métricas derivadas de las existentes.

Entre las variables añadidas destacan:

- ☐ Tasa de estabilidad laboral, que mide la duración promedio en los últimos empleos.
- ☐ Índice de comportamiento financiero, que combina puntualidad en pagos, relación deuda/ingresos y uso responsable del crédito.
- ☐ Métrica de confianza digital, que evalúa la consistencia en el uso de plataformas de consumo.

Además, se amplió el dataset sintético hasta 15.000 registros, distribuidos de manera más equilibrada entre distintos tipos de ingreso, nacionalidad y antigüedad laboral. Este incremento buscó reforzar la representatividad del modelo, reduciendo posibles sesgos en los resultados.

Para optimizar la estructura de los datos, se aplicaron técnicas de target encoding en las variables categóricas, mejorando la forma en que el modelo interpreta el impacto de cada categoría sobre la variable objetivo. También se implementaron métodos de regularización L1 y L2 durante el entrenamiento para evitar el sobreajuste, manteniendo la estabilidad y simplicidad del modelo.

6.3 Reentrenamiento del modelo

Con los datos ajustados, se llevó a cabo una nueva fase de entrenamiento. En esta etapa se compararon varios algoritmos supervisados —entre ellos Gradient Boosting, XGBoost y Random Forest— para identificar la mejor alternativa en términos de precisión, estabilidad y eficiencia computacional.

Tras diversas pruebas, el modelo XGBoost se consolidó como el más adecuado. Este algoritmo equilibró correctamente la precisión con el tiempo de procesamiento, y su estructura permitió captar relaciones complejas entre variables sin comprometer la interpretabilidad.

Durante el proceso se aplicó validación cruzada y optimización de hiperparámetros mediante Grid Search, ajustando el número de árboles, la profundidad máxima y la tasa de aprendizaje. Estas mejoras contribuyeron a estabilizar los resultados y a mejorar la generalización.

Asimismo, se incorporaron métricas complementarias como la precisión balanceada (balanced accuracy) y la pérdida logarítmica (log loss), que ofrecieron una visión más completa del desempeño del modelo frente a conjuntos de datos desbalanceados.

El reentrenamiento permitió comprobar una reducción significativa en la varianza de los resultados, lo que evidenció una mayor consistencia del sistema frente a diferentes escenarios de prueba.

6.4 Impacto en la precisión final

Los ajustes introducidos generaron una mejora notable en el rendimiento del modelo. La precisión pasó del 87 % inicial al 92 %, mientras que la métrica ROC-AUC alcanzó un 0,95, lo que indica una capacidad de discriminación excelente entre perfiles de riesgo alto y bajo.

El análisis de importancia de variables confirmó que los factores más influyentes en la predicción fueron el índice de comportamiento financiero, la tasa de estabilidad laboral y el nivel de ingresos, seguidos de la antigüedad en el país y la regularidad en los pagos digitales. Estos resultados fortalecen la hipótesis central del proyecto: los datos alternativos, correctamente estructurados, ofrecen una visión más justa y precisa del riesgo crediticio que los métodos tradicionales.

Además, el modelo ajustado mostró una mejor distribución de aciertos entre los distintos grupos socioeconómicos, reduciendo el sesgo hacia usuarios de ingresos medios y mejorando la clasificación de perfiles solventes dentro de colectivos más vulnerables.

Este avance no solo mejora el desempeño técnico del sistema, sino que refuerza el impacto social del proyecto, al demostrar que la innovación tecnológica puede contribuir a la inclusión financiera de poblaciones tradicionalmente excluidas.

En conjunto, las mejoras implementadas consolidan la base para la futura aplicación práctica del modelo en entornos reales. Los resultados alcanzados validan el enfoque adoptado y confirman que la integración de técnicas avanzadas de análisis de datos con criterios de equidad puede generar soluciones viables y sostenibles dentro del ecosistema fintech español.

7. MODELO DE MONETIZACIÓN

7.1 Estructura de pricing

Diseñamos un modelo de pricing que ofrece opciones de accesibilidad para clientes pequeños como rentabilidad en clientes grandes, ofreciendo dos modalidades principales, Pay-Per-Use y de Suscripción.

7.1.1 Modalidad Pay-Per-Use

La opción de pago por uso va especialmente enfocada a fintech nuevas o con volúmenes impredecibles, que prefieren evitar compromisos mensuales que impacten en sus gastos fijos.

Tarifa: 0,10€ por consulta de scoring **Sin compromiso mínimo Sin costes fijos**

Esta tarifa es entre 5 y 10 veces menor a consultas en bureaus tradicionales, que cuestan entre 0,50€ y 1,00€ (Belvo, 2026; GetApp, 2025; Techjockey, 2026), haciendo la propuesta inmediatamente atractiva para clientes cost-conscious.

Poniendo esto en perspectiva, una fintech que procese 1.000 solicitudes mensuales, de las cuales 300 carecen de historial tradicional, usando nuestra herramienta pagaría 30€ mensuales por evaluar ese segmento que actualmente rechaza directamente, sin análisis. El coste de oportunidad de rechazar un solo buen cliente superaría ampliamente este gasto, convirtiéndolo en una inversión.

7.1.2 Modalidad de Suscripción

Para clientes con volúmenes de evaluaciones establecidos o predecibles, ofrecemos planes de suscripción que reducen el coste unitario recompensando el compromiso mensual.

Plan Básico - 500€/mes:

- 10.000 consultas incluidas (0,05€ cada una)
- 0,08€ por consulta adicional
- Soporte por email con SLA 24h
- Documentación estándar
- Ideal para fintech procesando 500-1.500 solicitudes/mes

Plan Profesional - 2.000€/mes:

- 50.000 consultas incluidas (0,04€ cada una)
- 0,06€ por consulta adicional
- Soporte prioritario con SLA 4h
- Account manager asignado
- Reuniones trimestrales de revisión
- Ideal para fintech procesando 2.500-7.500 solicitudes/mes

Plan Enterprise - Precio personalizado:

- Volumen negociado (típicamente >100.000 consultas/mes)
- Coste unitario desde 0,02€
- SLA garantizado con penalizaciones
- Integraciones personalizadas
- Acceso a roadmap de producto
- Ideal para neobancos y grandes prestamistas

7.1.3 Lógica del modelo de precios

La estructura se basa en tres pilares estratégicos:

Captura de valor: Nuestro servicio permite a clientes aprobar préstamos que bajo esquemas tradicionales serían rechazados. Un préstamo de 3.000€ con margen del 8% genera 240€ de beneficio. Pagar 0,10€ por la evaluación representa 0,04% del valor generado, esto deja casi todo el valor al cliente.

Costes variables: Nuestro coste marginal por consulta incluye compute cloud (~0,001€), llamadas a APIs externas (~0,02€), y almacenamiento (~0,001€), totalizando ~0,022€. Con una tarifa de 0,10€ obtenemos un margen bruto del 78%, saludable para un negocio SaaS (Bessemer Venture Partners, 2024; Meritech Capital, 2025).

Incentivos al compromiso: Esto mediante los planes de suscripción, que logran reducir el coste unitario por consulta hasta en 60% (de 0,10€ a 0,04€ en plan Profesional), incentivando la contratación por volúmenes mayores y el compromiso a largo plazo, logrando con esto reducir nuestra tasa de cancelación, apostando por la fidelización.

7.2 Flujos de ingresos complementarios

Adicional al scoring básico, identificamos tres flujos de ingresos que podrían complementar y potenciar los ingresos al ser implementados en fases posteriores.

7.2.1 Servicios de consultoría

Asesoramiento a las fintech para lograr la optimización en todas las etapas de sus procesos de evaluación crediticia, no solo en el scoring. Lo que incluye: análisis de su funnel actual, identificación de cuellos de botella, recomendaciones sobre umbrales de aprobación óptimos y diseño de estrategias de segmentación.

Pricing: 5.000€-15.000€ por proyecto de consultoría

Target: 3-5 proyectos anuales

Ingresos estimados: 15.000€-75.000€/año

7.2.2 White-label de la plataforma

Esto consiste en licenciar nuestra tecnología completa a las fintech que opten por manejar el scoring internamente, siendo suministrado por nosotros el mantenimiento y actualizaciones del modelo.

Pricing: 10.000€ setup + 3.000€/mes de licencia

Target: 2-3 clientes en año 3

Ingresos estimados: 90.000€-120.000€/año

7.2.3 Venta de insights agregados

Generar reportes detallados de mercado basados en datos agregados y anonimizados (esto último clave para cumplir con la Ley de Protección de Datos). Ejemplo de reportes podrían ser: "Estado del crédito alternativo en España Q1 2026: tendencias, perfiles demográficos, tasas de aprobación por región".

Estos reportes serían de gran utilidad para inversores del sector fintech, consultoras, y entidades reguladoras.

Pricing: 2.000€-5.000€ por reporte trimestral

Target: 10-20 suscriptores

Ingresos estimados: 40.000€-80.000€/año

7.3 Proyecciones de ingresos

Construimos tres escenarios de adopción del servicio para así proyectar los ingresos en los próximos tres años.

7.3.1 Escenario conservador

Año 1:

- Meses 1-3: 2 clientes piloto (gratis, 0€ ingresos pero validación crítica)
- Meses 4-6: 3 clientes pagando en pay-per-use, promedio 200 consultas/mes
- Meses 7-9: 5 clientes, 2 migran a Plan Básico, 3 en pay-per-use → 1.300€/mes
- Meses 10-12: 7 clientes, 3 en Básico, 2 en Profesional, 2 en pay-per-use → cada uno → 180€/mes6.000€/mes

Total Año 1: ~48.000€

Año 2:

- Crecimiento a 15 clientes
- Mix: 6 en Básico, 4 en Profesional, 5 en pay-per-use
- Promedio mensual: ~15.000€

Total Año 2: 180.000€

Año 3:

- Crecimiento a 22 clientes
- Mix: 8 Básico, 7 Profesional, 5 pay-per-use, 2 Enterprise
- Promedio mensual: ~28.000€

Total Año 3: 336.000€

7.3.2 Escenario moderado

Asume adopción 30% superior al escenario conservador:

- Año 1: 65.000€
- Año 2: 250.000€
- Año 3: 480.000€

7.3.3 Escenario optimista

Asume adopción acelerada con entrada de 1-2 neobancos grandes:

- Año 1: 90.000€
- Año 2: 380.000€
- Año 3: 720.000€

Para efectos de nuestra planificación financiera, así como la captación de inversión, utilizaremos el escenario conservador, permitiendo superar las expectativas en el caso que la adopción resulte más rápida y permitiendo un mejor margen de maniobra con los inversionistas.

7.4 Métricas clave del modelo de negocio

Se hará seguimiento a indicadores específicos para evaluar salud y sostenibilidad del modelo de monetización:

Customer Acquisition Cost (CAC): Coste total de ventas y marketing dividido por número de clientes nuevos.

Objetivo: <3.000€ por cliente.

Lifetime Value (LTV): Ingreso promedio por cliente durante toda su relación con nosotros. Objetivo año 3: >18.000€.

LTV/CAC Ratio: Indicador de eficiencia económica.

Objetivo: >6:1.

Churn Rate mensual: Porcentaje de clientes que cancelan cada mes.

Objetivo: <3%.

Net Revenue Retention: Porcentaje de ingresos retenidos año-sobre-año de la cohorte existente, incluyendo expansion revenue.

Objetivo: >110% (clientes existentes gastan más con el tiempo).

Gross Margin: (Ingresos - Costes variables) / Ingresos.

Objetivo: >75%.

8. EQUIPO Y RECURSOS

8.1 Estructura del equipo fundador

Este proyecto requiere un equipo fundador multidisciplinario, que logre cubrir un mínimo de competencias técnicas, comerciales y operativas. Proponemos una estructura inicial de cuatro personas:

Perfil 1 - CEO / Business Lead: Responsable de estrategia general, relaciones con inversores, y desarrollo de negocio. Idealmente con experiencia previa en fintech (product manager, business development, o fundador de startup anterior). Habilidades clave: venta B2B, comprensión del sector financiero, capacidad de fundraising y networking en ecosistema emprendedor.

Perfil 2 - CTO / Tech Lead: Responsable de la arquitectura técnica, infraestructura cloud, y decisiones de stack tecnológico. Experiencia mínima de 5 años en ingeniería de software, con conocimientos sólidos en APIs, bases de datos, y sistemas distribuidos. Deseable experiencia en fintech o ambientes de alto volumen transaccional.

Perfil 3 - Data Scientist / ML Lead: Responsable del desarrollo, entrenamiento y optimización continua de los modelos de machine learning. Formación avanzada en estadística o computer science (preferiblemente PhD o Máster especializado). Experiencia demostrable en proyectos de ML en producción, no solo académicos. Dominio de Python, scikit-learn, XGBoost, y frameworks de experimentación.

Perfil 4 - Full-Stack Developer: Responsable de implementación de features, mantenimiento de la API, y desarrollo de herramientas internas. Experiencia en Python (FastAPI), PostgreSQL, Redis, y deployment en cloud (AWS/GCP/Azure). Capacidad de trabajar en todo el stack desde base de datos hasta endpoints de API.

Esta estructura de cuatro personas cubre las áreas críticas para un MVP funcional. A medida que el negocio escale, serán incorporados perfiles adicionales.

8.2 Plan de crecimiento del equipo

El cronograma de contrataciones se alinea con hitos de negocio y disponibilidad de financiación:

Meses 0-6 (Fase de desarrollo MVP):

- Equipo fundador (4 personas)
- Opcionalmente 1 freelance de frontend para dashboard de clientes

Meses 7-12 (Primeros clientes pagando):

- Contratación 5: Sales / Business Development Representative
  - Perfil:
    - Experiencia en venta B2B de soluciones SaaS
    - Network en sector fintech deseable
    - Responsable de prospección y cierre de nuevos clientes

Meses 13-18 (Expansión de cliente base):

- Contratación 6: Customer Success Manager
  - Perfil:
    - Gestiona onboarding de clientes nuevos
    - Monitoriza satisfacción y previene churn
    - Identifica oportunidades de upsell
- Contratación 7: DevOps Engineer
  - Perfil:
    - Optimiza infraestructura cloud
    - Implementa CI/CD robusto
    - Gestiona monitorización y alertas

Meses 19-24 (Operaciones maduras):

- Contratación 8: Data Engineer
  - Perfil:
    - Construye pipelines de datos más sofisticados
    - Gestiona integraciones con fuentes de datos externas
    - Optimiza procesamiento batch
- Contratación 9: Compliance & Legal Officer (media jornada)
  - Perfil:
    - Asegura cumplimiento GDPR
    - Gestiona relaciones con AEPD
    - Revisa contratos con clientes

Este plan lleva el equipo de 4 a 9 personas en dos años, tamaño manejable para una startup early-stage.

8.3 Recursos tecnológicos necesarios

8.3.1 Infraestructura cloud

Proveedor seleccionado: AWS (Amazon Web Services) **Presupuesto mensual inicial:** 400€ **Presupuesto mensual año 2:** 1.200€

Servicios utilizados:

- EC2 (servidores virtuales): 2 instancias t3.medium para API (150€/mes)
- RDS PostgreSQL: Base de datos gestionada, 1 instancia db.t3.small (80€/mes)
- ElastiCache Redis: Cache en memoria, 1 nodo cache.t3.micro (50€/mes)
- S3: Almacenamiento de modelos y backups (20€/mes)
- CloudFront: CDN para reducir latencias globales (30€/mes)
- Route53: DNS management (5€/mes)
- CloudWatch: Monitorización y logs (40€/mes)
- Secrets Manager: Gestión de credenciales (10€/mes)
- Backup automático y disaster recovery (15€/mes)

Justificación de AWS vs. alternativas:

Consideramos GCP y Azure. AWS ofrece mayor madurez en servicios financieros (muchas fintech ya lo usan, facilitando integraciones), programa de créditos para startups (hasta $100k en año 1), y documentación/community más extensas (Amazon Web Services, 2025 y 2026; Stack Overflow, 2025)

8.3.2 Herramientas SaaS

Desarrollo:

- GitHub Enterprise ($21/usuario/mes × 4 = $84/mes): Control de versiones y CI/CD
- DataDog ($15/host/mes × 3 = $45/mes): Monitorización APM
- Sentry ($26/mes): Error tracking
- **Total:** ~150€/mes

Productividad:

- Google Workspace ($12/usuario/mes × 4 = $48/mes): Email, docs, calendar
- Slack ($8/usuario/mes × 4 = $32/mes): Comunicación interna
- Notion ($10/usuario/mes × 4 = $40/mes): Knowledge base y documentación
- **Total:** ~120€/mes

Ventas y CRM:

- HubSpot CRM (plan gratuito inicialmente)
- LinkedIn Sales Navigator ($79/mes): Prospección B2B
- **Total:** ~80€/mes

Total herramientas SaaS: ~350€/mes

8.3.3 Hardware y equipamiento

Cada miembro del equipo requiere:

- Laptop (MacBook Pro o equivalente): 2.000€
- Monitor externo: 300€
- Accesorios (teclado, mouse, auriculares): 200€

Inversión inicial: 4 × 2.500€ = 10.000€

8.3.4 Oficina y espacio de trabajo

Meses 1-6: Trabajo remoto completo (ahorro de costes inicialmente)

Meses 7+: Coworking en Madrid (Utopicus, Loom, Impact Hub)
- Coste: ~200€/persona/mes
- 4 personas = 800€/mes
- Incluye: mesas, internet, salas de reuniones, café

Evitamos oficina propia para mantener flexibilidad y bajos costes fijos.

8.4 Inversión inicial requerida

Consolidando todas las necesidades, la inversión inicial para 18 meses de operación se estructura así:

Salarios (18 meses):
- 4 fundadores: Salarios modestos de 2.500€/mes promedio × 4 × 18 = 180.000€
- 2 contrataciones adicionales (meses 7-18): 3.000€/mes × 2 × 12 = 72.000€
- **Subtotal salarios:** 252.000€

Infraestructura y tecnología (18 meses):
- Cloud AWS: 400€/mes × 6 + 800€/mes × 12 = 12.000€
- Herramientas SaaS: 350€/mes × 18 = 6.300€
- Hardware: 10.000€ (inicial) + 5.000€ (contrataciones) = 15.000€
- **Subtotal tech:** 33.300€

Operaciones (18 meses):
- Coworking: 800€/mes × 12 = 9.600€
- Viajes y eventos: 2.000€/mes × 18 = 36.000€
- Marketing y contenido: 1.000€/mes × 18 = 18.000€
- Legal y compliance: 1.500€/mes × 18 = 27.000€
- **Subtotal operaciones:** 90.600€

Contingencia (15%): 56.000€

Total inversión inicial: 432.000€

Esta cifra se puede redondear a un valor psicológicamente relevante el para el pitch a inversores: **450.000€**

Con esta cantidad se logra cubrir íntegramente un runway de 18 meses, asumiendo un escenario conservador donde solo aparecen ingresos significativos a partir del mes 12. En caso de que la adopción sea más rápida, el runway se irá extendiendo.

8.5 Estrategia de captación de financiación

Para reunir los 450.000€, proponemos una combinación de fuentes:

Ronda Pre-Seed: 350.000€

- Business angels del sector fintech (150.000€)
- Fondo de pre-seed especializado en SaaS B2B (200.000€)
- Valoración pre-money: 1.5M€
- Dilución: 23%

Subvenciones y grants: 50.000€

- ENISA Jóvenes Emprendedores, hasta 75.000€ disponible. (Enisa, 2026)
- Grants de AWS Activate, Google Cloud Startups
- Programas de aceleración, South Summit seleccionados reciben 50k-100k (South Summit, 2026).

Aportación fundadores: 50.000€

- 12.500€ por fundador
- Demuestra skin in the game a inversores

Esta estructura minimiza dilución (sub-25%) manteniendo suficiente capital para ejecutar plan inicial.

9. EVALUACIÓN DE LA EFECTIVIDAD DE LAS MEJORAS

9.1 Métricas de rendimiento del modelo

La evaluación rigurosa del modelo es un elemento fundamental para poder garantizar que cada una de las mejoras implementadas sean capaces de generar un valor real en la plataforma. Implementamos un framework de métricas que abarquen tanto aspectos técnicos como de negocio.

9.1.1 Métricas técnicas primarias

Accuracy (Exactitud): Refleja la proporción de predicciones correctas sobre el total. En nuestro modelo final: 78,5%.

Accuracy = (Predicciones correctas) / (Total predicciones)

= (142 + 87 + 31) / 200

= 0.785

Esta es una métrica básica, aunque puede ser engañosa en datasets desbalanceados. Por ello es necesario complementar con métricas más sofisticadas.

Precision (Precisión): De todas las veces que el modelo predijo "bajo riesgo", ¿cuántas veces acertó?

Precision_low = 142 / (142 + 12 + 0) = 0.922

Alta precisión en la clase "low risk" significa que cuando recomendamos aprobar un préstamo, probablemente es seguro hacerlo.

Recall (Sensibilidad): De todos los usuarios que realmente son bajo riesgo, ¿cuántos identificamos?

Recall_low = 142 / (142 + 8 + 0) = 0.947

Un alto recall significa que no estamos perdiendo buenos clientes al clasificarlos como falsos negativos.

F1-Score: Media armónica de precision y recall. Balancea ambas métricas en un solo número.

F1 = 2 × (Precision × Recall) / (Precision + Recall)

= 2 × (0.922 × 0.947) / (0.922 + 0.947)

= 0.934

Nuestro F1-score de 93.4% para la clase "low risk" indica rendimiento excelente en identificar buenos pagadores.

AUC-ROC (Area Under Curve - Receiver Operating Characteristic): Mide la capacidad del modelo para discriminar entre clases, independientemente del threshold elegido. Nuestro valor de 90.2% se interpreta como: si tomamos de forma aleatoria a un usuario de bajo riesgo y uno de alto riesgo, hay 90.2% de probabilidad de que el modelo le asigne un mayor score al de bajo riesgo.

9.1.2 Análisis de matriz de confusión

La matriz revela dónde el modelo acierta y dónde falla:

	Predicho: Low	Predicho: Med	Predicho: High	Total Real
Actual: Low	**142**	8	0	**150**
Actual: Med	12	**87**	11	**110**
Actual: High	0	9	**31**	**40**

Total Predicho	154	104	42	**300**

Insights clave:

1. **Cero falsos positivos críticos:** Nunca clasificamos un alto riesgo como bajo riesgo. Esto es fundamental, ya que aprobar a un usuario que terminará en default es costoso para las fintech.
2. **Falsos negativos tolerables:** 8 usuarios de bajo riesgo fueron clasificados como medium risk. Esto significa que algunos buenos clientes requerirán una revisión manual, más a fondo, pero no serán rechazados completamente siendo posible aún su recuperación como cliente.
3. **Confusión en medium risk:** La categoría intermedia presenta mayor ambigüedad, lo cual es perfectamente razonable, ya que en la realidad, hay clientes genuinamente difíciles de clasificar.

9.1.3 Curva ROC y selección de threshold

Generamos la curva ROC variando el threshold de decisión, lo cual nos permite ajustar el balance entre precisión y recall, según las preferencias de cada cliente.

Un cliente conservador, como puede ser un banco tradicional, podría preferir un threshold alto: “solo aprobamos si estamos muy seguros”. Esto maximiza precisión a costa de recall, por lo cual terminamos rechazando un mayor número de buenos clientes potenciales.

Un cliente agresivo, caso de una fintech de crecimiento rápido, podría preferir un threshold bajo: aprovando más, aumentando recall, pero reduciendo precision, derivando en la aprobación de algunos clientes riesgosos como costo de este tipo de estrategias.

Nuestro threshold por defecto estará calibrado en el punto que maximiza F1-score, balance razonable para la mayoría de casos.

9.2 Validación estadística

Para asegurar que los resultados del modelo no son producto del azar o el overfitting, aplicamos técnicas estadísticas rigurosas de validación.

9.2.1 Cross-validation k-fold

Para esta validación, dividimos el dataset en 5 partes (folds). Entrenamos el modelo 5 veces, cada vez usando 4 folds para training y 1 para testing, rotando cuál se usa para testing.

Resultados:

Fold 1: F1 = 0.776, Accuracy = 0.775

Fold 2: F1 = 0.784, Accuracy = 0.790

Fold 3: F1 = 0.781, Accuracy = 0.785

Fold 4: F1 = 0.779, Accuracy = 0.780

Fold 5: F1 = 0.780, Accuracy = 0.785

Promedio: F1 = 0.780 ± 0.003

La desviación estándar de 0.003 indica que el rendimiento es estable independientemente de cómo dividamos los datos. Lo cual valida el modelo en cualquier circunstancia.

9.2.2 Test en datos completamente nuevos

Generamos un conjunto adicional de 200 usuarios que el modelo nunca vio durante training ni validation. Este simula lo que ocurrirá en producción con usuarios reales.

Resultados en test set nuevo:

Accuracy: 76.8%

F1-Score: 76.2%

AUC-ROC: 89.1%

Ligera degradación respecto al validation set (~2%), perfectamente normal. Confirma que el modelo generaliza razonablemente bien.

9.2.3 Bootstrap confidence intervals

Aplicamos bootstrap resampling (1000 iteraciones) para calcular intervalos de confianza del 95% para nuestras métricas:

Accuracy: 78.5% [76.2% - 80.9%]

F1-Score: 78.0% [75.5% - 80.4%]

AUC-ROC: 90.2% [88.1% - 92.1%]

Estos intervalos indican el rango donde esperamos se sitúe el rendimiento real con alta probabilidad. Incluso en el peor escenario del intervalo, tomando el límite inferior, el modelo sigue siendo consistentemente efectivo.

9.3 Comparación con baseline y competidores

Para contextualizar nuestros resultados, los comparamos contra alternativas.

9.3.1 Baseline naive

Un modelo primitivo, que siempre predice la clase mayoritaria (medium risk) alcanzaría accuracy de 55% (110/200). Nuestro 78.5% representa mejora de 42% relativo sobre esta baseline.

9.3.2 Regresión logística simple

Entrenamos un modelo de regresión logística usando sólo las variables crudas (sin feature engineering). Resultados:

Accuracy: 72.0%

F1-Score: 71.5%

La mejora de 6.5 puntos porcentuales demuestra el valor del feature engineering sofisticado que implementamos.

9.3.3 Modelos tradicionales (FICO/VantageScore)

Según autores como Khandani et all. (2010), Siddiqi (2017), así como informes de FICO (2023) y Vantage Store (2024), los modelos FICO tradicionales alcanzan accuracy del 75-80% en poblaciones con historial. Nuestro 78.5% se sitúa dentro de este rango, notable considerando que:

1. Usamos datos completamente diferentes (consumo digital vs. historial bancario)
2. Nuestro dataset de entrenamiento es mucho menor
3. Estamos en fase de prototipo, no décadas de refinamiento

9.4 Análisis de importancia de features

El XGBoost nos permite cuantificar cuánto contribuye cada una de las variables al poder predictivo del modelo.

#	Variable (Feature)	Importancia (%)	Categoría de Análisis
1	avg_punctuality_all_apps	**14.5%**	Comportamiento de Pago
2	total_digital_spending	**13.2%**	Capacidad Económica
3	engagement_score	**11.8%**	Actividad Digital
4	glovo_punctuality	**9.5%**	Hábitos de Consumo
5	rfm_score	**8.7%**	Valor Transaccional (RFM)
6	spending_income_ratio	**7.2%**	Salud Financiera

7	active_apps_count	**6.8%**	Estilo de Vida Digital
8	movistar_punctuality	**6.3%**	Compromisos Recurrentes
9	days_since_registration	**5.9%**	Estabilidad / Antigüedad
10	spending_trend	**5.1%**	Tendencia de Gasto

Insights:

- Las top 3 features son todas derivadas (no variables crudas), validando el trabajo de feature engineering
- La puntualidad agrupada explica >14% de las decisiones, confirmando nuestra hipótesis de que es el indicador más fuerte
- Variables individuales de apps específicas (glovo_punctuality, movistar_punctuality) también son relevantes, sugiriendo que la información granular añade valor al modelo.
- Features de tendencia temporal (spending_trend) aparecen en top 10, esto jos indica que la evolución en el tiempo del comportamiento del individuo importa tanto como el estado actual.

9.5 Análisis de errores y casos edge

Investigamos sistemáticamente los errores presentes en el modelo, para así identificar patrones que pudieran existir y oportunidades de mejora.

9.5.1 Falsos negativos

Estos son aquellos usuarios buenos, pero que el modelo clasifica como malos. Aquí examinamos los 8 casos de bajo riesgo clasificados como medium:

Patrón común: Usuarios bastante nuevos (días_since_registration < 90), con comportamiento excelente pero historia corta. El modelo se muestra conservador con usuarios sin track record largo.

Implicación: Podríamos crear una categoría especial "low risk - short history", a quienes se les asigne límites de crédito bajos, pero con posibilidades reales que escalen conforme acumulen más datos.

9.5.2 Falsos positivos

Estos son usuarios malos clasificados como buenos. No tuvimos falsos positivos graves (high risk → low risk), pero sí 9 casos de high risk → medium risk.

Patrón común: Usuarios con gasto alto pero puntualidad limítrofe (80-85%). El gasto elevado confunde al modelo, haciendo que interprete que tienen capacidad de pago, cuando en realidad se trata de un problema de disciplina financiera.

Implicación: Podríamos añadir un hard constraint: si puntualidad < 80%, nunca clasificar como low risk, esto independientemente de otras variables favorables.

9.5.3 Usuarios autónomos

Los autónomos presentan mayor tasa de error (error rate 28% vs. 22% general). La alta volatilidad de sus ingresos, inherente a su tipo de ingresos, dificulta la clasificación dentro del modelo.

Implicación: Se confirma la necesidad de desarrollar un modelo especializado para este segmento de usuarios en futuras iteraciones.

9.6 Simulaciones de impacto en negocio

En esta etapa. traducimos las métricas técnicas en cómo sería el impacto económico real para nuestros clientes.

Escenario base:

- Fintech recibe 1.000 solicitudes/mes
- 400 sin historial (actualmente son rechazadas)
- De esas 400, asumimos ~25% son realmente buenos (100 personas)

Con nuestro modelo:

- Evaluamos las 400
- Identificamos correctamente ~95 de los 100 buenos (recall 94.7%)
- Aprobamos algunos malos adicionales (falsos positivos)

Cálculo de valor:

Concepto	Detalle / Cálculo	Valor
Nuevas Operaciones	Préstamos adicionales aprobados	95 unidades
Ingreso Bruto Incremental	95 préstamos × 3.000€ (Ticket prom.)	285.000€
Beneficio Marginal	285.000€ × 8% (Margen)	**22.800€**
Costo por Riesgo (Default)	12 usuarios × 15% (Default) × 3.000€ × 0.7*	**-1.620€**
Beneficio Neto Mensual	Beneficio Marginal - Pérdidas por Default	**21.180€**
Inversión en Servicio	400 consultas × 0,10€	**40€**
ROI Mensual	(21.180€ - 40€) / 40€	**52.850 %**

Este sencillo análisis cuantitativo demuestra el value proposition, con un gran impacto en los ingresos del cliente.

10. GESTIÓN DE LA PRIVACIDAD Y ÉTICA DEL DATO

10.1 Marco regulatorio aplicable

El tratamiento de datos personales para evaluación crediticia en España está sujeto a un marco regulatorio complejo, que combina leyes de protección de datos, cada vez más estricta dentro de la Union Europea, con toda la normativa específica del sector financiero.

10.1.1 Reglamento General de Protección de Datos (RGPD)

El RGPD establece principios fundamentales que rigen toda operación de datos:

Licitud, lealtad y transparencia: Solo procesamos datos con base legal clara mediante el consentimiento explícito del usuario o ejecución de contrato. Informamos al usuario exactamente qué datos recopilamos y su finalidad.

Limitación de la finalidad: Los datos recogidos para scoring crediticio no pueden utilizarse posteriormente para otros fines (por ejemplo, marketing) sin un consentimiento adicional específico del usuario.

Minimización de datos: Recopilamos solo información estrictamente necesaria para la evaluación. No pedimos acceso a mensajes privados, contactos, fotos, o cualquier dato no relevante para la decisión crediticia.

Exactitud: Implementamos mecanismos que permitan al usuario corregir datos incorrectos que afecten su puntuación.

Limitación del plazo de conservación: Los datos se borran automáticamente tras períodos definidos:

- Datos transaccionales después de 24 meses
- Puntuaciones calculadas después de 12 meses, a menos que exista obligación legal de conservación más larga.

Integridad y confidencialidad: Se aplica la encriptación de datos en tránsito (TLS 1.3) y en reposo (AES-256). Implementando controles de acceso estrictos mediante autenticación multifactor para empleados.

Responsabilidad proactiva: Documentamos todas las decisiones de diseño relacionadas con privacidad. Realizamos evaluaciones de impacto (DPIA - Data Protection Impact Assessment) antes de procesar nuevas categorías de datos.

10.1.2 Ley Orgánica de Protección de Datos (LOPDGDD)

La normativa española complementa el RGPD con requisitos adicionales:

Artículo 11 (Consentimiento): El consentimiento debe ser específico para cada finalidad. No vale un consentimiento genérico para "mejorar nuestros servicios".

Artículo 20 (Decisiones automatizadas): Los usuarios tienen derecho a no ser objeto de decisiones basadas únicamente en tratamiento automatizado que produzcan efectos jurídicos. Esto implica que nuestro scoring no puede ser el único criterio de decisión para aprobar o no a un usuario, la fintech cliente debe considerar factores adicionales o permitir revisión humana en caso de ser necesario o solicitado.

Artículo 28 (Garantías de los derechos digitales): Los usuarios deben poder ejercer sus derechos de acceso, rectificación, supresión, limitación, portabilidad y oposición mediante canales digitales sencillos.

10.1.3 Circular del Banco de España y normativa sectorial

Aunque no somos una entidad de crédito directamente, las fintech que usan nuestro servicio sí lo son, por lo que las herramientas que les ofrecemos deben estar siempre alineadas con la normativa sectorial vigente:

Circular 4/2017 sobre normas de información financiera: Establece cómo las entidades deben documentar y justificar sus modelos de evaluación de riesgo. Nuestra documentación técnica debe facilitar que clientes cumplan estos requisitos.

Directiva MiFID II (adaptada en España): Aunque más relevante para inversión que crédito, establece principios de governance de algoritmos que consideramos buenas prácticas: testing regular, documentación de cambios, comités de validación.

10.2 Implementación práctica del cumplimiento

Traducimos los requisitos legales en procesos operativos concretos.

10.2.1 Flujo de consentimiento

Cuando un usuario solicita un préstamo en una fintech cliente y esta desea usar nuestro scoring:

Paso 1 - Información previa: Antes de solicitar consentimiento, mostramos una pantalla explicativa:

Evaluación crediticia con datos alternativos

Para evaluar tu solicitud sin necesidad de historial bancario, podemos analizar tu comportamiento de pago en aplicaciones que uses regularmente.

¿Qué datos accederemos?

- Número de pedidos/compras/viajes
- Importes totales (no detalles de productos)
- Puntualidad de pagos
- Antigüedad como usuario

¿Qué NO accederemos?

- Productos específicos que compraste
- Direcciones de entrega
- Mensajes o comunicaciones
- Datos de otras personas

Tu información se usará únicamente para evaluar esta solicitud de crédito y se eliminará tras 12 meses.

[Ver política completa] [Continuar]

Paso 2 - Consentimiento granular: Permitimos selección individual por aplicación:

Autorizo el acceso a mis datos de:

☑ Glovo (pedidos de comida y delivery)

☑ Cabify (viajes y transporte)

☐ Zara (compras online)

☑ Movistar (facturación móvil)

Entiendo que:

- Puedo autorizar solo las apps que elija

- Más datos mejoran la precisión de la evaluación

- Puedo revocar el acceso en cualquier momento

[Rechazar todo] [Aceptar seleccionadas]

Esta granularidad cumple con el principio de consentimiento específico.

Paso 3 - Registro de consentimiento: Almacenamos un registro auditable:

```
json
{
  "user_id": "usr_12345",
  "timestamp": "2025-01-15T10:23:45Z",
  "ip_address": "91.123.45.67",
  "consent": {
```

```
    "glovo": true,
    "cabify": true,
    "zara": false,
    "movistar": true
  },
  "expiry_date": "2026-01-15T10:23:45Z",
  "withdrawal_possible": true
}
```


10.2.2 Derechos de los usuarios

Implementamos un portal de privacidad donde los usuarios ejercen sus derechos:

Derecho de acceso:

Se define un Endpoint `/privacy/access` que devuelve todos los datos que tenemos sobre un usuario:

GET /privacy/access?user_id=usr_12345

Response:


```
{
  "personal_data": {
    "age": 32,
    "registration_date": "2024-07-15"
  },
```

```
  "app_data": {
    "glovo": {
      "total_orders": 45,
      "avg_ticket": 23.50,
      "punctuality": 0.96,
      "total_spent": 1057.50
    },
    [...]
  },
  "scoring_history": [
    {
      "date": "2025-01-15",
      "score": 718,
      "risk_category": "low_risk"
    }
  ],
  "data_sources": ["glovo_api", "cabify_api", "movistar_api"],
  "retention_until": "2026-01-15"
}
```


Derecho de rectificación:

Si un usuario detecta un error (por ejemplo, transacciones que no reconoce), puede reportarlo:

POST /privacy/rectify

```
{
  "user_id": "usr_12345",
  "field": "glovo_total_orders",
  "claimed_value": 40,
  "current_value": 45,
  "reason": "5 pedidos fueron cancelados pero aparecen como completados"
}
```

Esto genera un ticket de revisión manual. Si se confirma el error, corregimos los datos y recalculamos el score.

Derecho de supresión ("derecho al olvido"):

DELETE /privacy/delete?user_id=usr_12345

Acciones ejecutadas:

1. Eliminar datos transaccionales de todas las apps
2. Eliminar scores calculados
3. Anonimizar registros en logs (reemplazar user_id con hash)
4. Notificar a fintech cliente que debe eliminar datos relacionados
5. Enviar confirmación al usuario por email

Excepción: Sólo si existe obligación legal de conservación (ej. investigación de fraude), mantenemos los datos pero bloqueamos su uso para scoring futuro.

Derecho de portabilidad:

Exportamos datos en formato estándar (JSON):

```
GET /privacy/export?user_id=usr_12345
```

Este comando descarga un archivo JSON con todos los datos en formato legible por máquina, facilitando que el usuario los traslade a otro proveedor si existe.

Derecho de oposición al tratamiento automatizado:

Permitimos que usuarios exijan revisión humana:

```
POST /privacy/manual_review

{

  "user_id": "usr_12345",

  "score_id": "score_789",

  "reason": "Creo que el score no refleja mi situación real"

}
```

Esto activa una solicitud para revisión manual por parte de la fintech cliente, que debe considerar factores adicionales no capturados por el modelo.

10.2.3 Anonimización y pseudonimización

Aplicamos diferentes niveles de protección según el uso de los datos:

Nivel 1 - Datos en producción (pseudonimizados):

Los datos operativos usan identificadores pseudónimos en lugar de información directamente identificable:

En lugar de:

```
{
  "name": "Juan García",
  "email": "juan.garcia@email.com",
  "dni": "12345678A"
}
```

Usamos:

```
{
  "user_id": "usr_12345",  // Hash irreversible del DNI
  "age": 32,               // Mantenemos edad pero no fecha de nacimiento exacta
}
```

Nivel 2 - Datos analíticos (anonimizados):

Para análisis internos, agregamos y anonimizamos completamente:

En lugar de registros individuales, trabajamos con agregaciones:

"Usuarios de 30-35 años en Madrid:

- Gasto promedio: 1.250€
- Puntualidad promedio: 91%
- Distribución de riesgo: 35% low, 50% medium, 15% high"

Nivel 3 - Datos de investigación (synthetic data):

Para publicaciones académicas o demostraciones, generamos datos completamente sintéticos que preservan propiedades estadísticas, pero no corresponden a personas reales.

10.2.4 Seguridad técnica

Encriptación en tránsito:

Todas las comunicaciones usan TLS 1.3 con perfect forward secrecy. Configuración:

```
ssl_protocols TLSv1.3;

ssl_ciphers 'TLS_AES_128_GCM_SHA256:TLS_AES_256_GCM_SHA384';

ssl_prefer_server_ciphers off;
```

Encriptación en reposo: Bases de datos encriptadas con AES-256:

python

PostgreSQL con extensión pgcrypto

```
CREATE EXTENSION pgcrypto;
```

Columnas sensibles encriptadas

```
CREATE TABLE user_data (

  user_id VARCHAR PRIMARY KEY,

  sensitive_data BYTEA,  -- Encriptado con pgp_sym_encrypt()

  ...

);
```

Control de acceso: Implementación de RBAC (Role-Based Access Control):

yaml

Roles:

  - admin: Acceso completo (solo CTO y DPO)

  - engineer: Lectura de datos operativos, sin PII

  - analyst: Solo datos agregados/anonimizados

  - support: Acceso limitado solo con ticket válido

Todos los accesos requieren:

  - MFA (autenticación de dos factores)

  - IP whitelisting (solo desde VPN corporativa)

  - Logging exhaustivo de todas las operaciones

```

**Auditoría continua:**

Logs de acceso a datos sensibles:

2025-01-15 10:23:45 | user:engineer_001 | action:read | resource:user_12345 | reason:customer_support_ticket_789 | approved:yes

Estos logs son inmutables (append-only) y se revisan mensualmente buscando patrones anómalos.

### 10.3 Consideraciones éticas más allá del cumplimiento legal

El cumplimiento de GDPR es el mínimo legal, pero aspiramos a estándares éticos más elevados.

#### 10.3.1 Prevención de sesgos algorítmicos

Los modelos de ML pueden perpetuar o amplificar sesgos existentes en los datos de entrenamiento. Implementamos controles específicos:

**Auditoría de equidad por grupo demográfico:**
```

Medimos si el modelo discrimina injustamente por edad, género, o nacionalidad:

python

Análisis de disparate impact

```
for grupo in ['18-25', '26-35', '36-50', '50+']:
    tasa_aprobacion_grupo = aprobaciones[grupo] / solicitudes[grupo]
    tasa_aprobacion_total = aprobaciones_total / solicitudes_total

    ratio = tasa_aprobacion_grupo / tasa_aprobacion_total

    # Regla del 80%: ningún grupo debe tener ratio < 0.8
    if ratio < 0.8:
        ALERTA: "Posible discriminación contra grupo " + grupo
```

Resultados de nuestro análisis:

Grupo 18-25: Ratio 0.85 ✓

Grupo 26-35: Ratio 0.98 ✓

Grupo 36-50: Ratio 1.02 ✓

Grupo 50+: Ratio 0.88 ✓

Todos los grupos superan el threshold del 80%

Análisis de calibración:

Verificamos que las probabilidades predichas por el modelo sean realistas:

Cuando el modelo dice "30% de probabilidad de default":

¿Realmente aproximadamente el 30% de esos casos terminan en default?

Grupos de calibración:

0-10% predicho: 7% observado (dentro del margen)

10-20% predicho: 15% observado ✓

20-30% predicho: 24% observado ✓

Buen nivel de calibración = predicciones confiables

Variables protegidas:

No incluimos directamente variables protegidas (etnia, religión, orientación sexual) ya que sería ilegal. Pero vigilamos proxies indirectos:

Por ejemplo, el código postal podría ser proxy de etnia en áreas altamente segregadas. Realizamos análisis para detectar si el modelo toma decisiones diferentes en función del código postal de manera que correlacione con variables protegidas.

Si detectamos esto, eliminamos esas variables o aplicamos técnicas de fairness (re-weighting, adversarial debiasing).

10.3.2 Explicabilidad de decisiones

El RGPD otorga derecho a explicación de decisiones automatizadas. Implementamos esto mediante:

SHAP values (SHapley Additive exPlanations):

Para cada predicción, calculamos cuánto contribuyó cada variable:

Usuario usr_12345 - Score: 718 (Low Risk)

Contribuciones:

avg_punctuality: +120 puntos (muy alta puntualidad)

total_digital_spending: +80 puntos (gasto saludable)

days_since_registration: +40 puntos (usuario establecido)

engagement_score: +30 puntos (usa múltiples apps)

spending_volatility: -15 puntos (algo de variabilidad)

...

Baseline (usuario promedio): 650 puntos

Score final: 718 puntos

Esta explicación se incluye en la respuesta de la API y puede mostrarse al usuario final.

Documentación de lógica del modelo:

Mantenemos un documento que explica en lenguaje no técnico cómo funciona el sistema:

"Nuestro modelo evalúa principalmente tres aspectos:

1. Puntualidad de pagos (peso 40%):

   Si pagas tus servicios a tiempo consistentemente, recibes puntuación alta.

2. Estabilidad de gastos (peso 35%):

   Gastos regulares y predecibles sugieren ingresos estables.

3. Diversificación (peso 25%):

Usar múltiples servicios digitales indica integración económica."

10.3.3 Transparencia con usuarios finales

Creamos una página pública "Cómo funciona nuestro scoring" que explica:

- Qué datos usamos
- Qué datos NO usamos
- Cómo se calcula la puntuación
- Cómo mejorar tu score
- Cómo ejercer tus derechos

Ejemplos de buenas prácticas que comunicamos:

Cómo mejorar tu score de scoring alternativo:

✓ Paga siempre a tiempo (lo más importante)

✓ Usa servicios regularmente durante varios meses

✓ Mantén patrones de gasto consistentes

✓ Diversifica entre diferentes tipos de servicios

✗ No manipules el sistema con transacciones falsas (lo detectaremos)

✗ No compartas tu cuenta con otras personas

✗ No canceles pedidos frecuentemente

10.3.4 Comité de ética interno

Estableceremos un comité que se reúne trimestralmente para revisar:

Composición:

- 1 miembro del equipo técnico (Data Scientist)
- 1 miembro del equipo legal/compliance
- 1 asesor externo (académico especializado en ética de IA)
- 1 representante de consumidores (rotatorio)

Funciones:

- Revisar casos problemáticos reportados por usuarios
- Evaluar cambios significativos en el modelo antes de deployment
- Auditar métricas de fairness trimestralmente
- Proponer mejoras en políticas de privacidad y transparencia

Poder de veto:

El comité puede bloquear el despliegue de actualizaciones del modelo que considere problemáticas desde perspectiva ética, incluso si son técnicamente superiores.

10.4 Gestión de incidentes de seguridad

A pesar de todas las precauciones, asumimos que eventualmente podría ocurrir una brecha de seguridad. Preparamos un protocolo de respuesta:

10.4.1 Detección

Monitorización 24/7:

- Alertas automáticas ante patrones anómalos de acceso
- Detección de exfiltración de datos mediante análisis de tráfico
- Honeypots para detectar intentos de intrusión

Whistleblowing:

- Canal anónimo para que empleados reporten prácticas problemáticas
- Protección contra represalias

10.4.2 Contención (primeras 24 horas)

1. **Hora 0-1:** Aislar sistemas afectados de la red
2. **Hora 1-4:** Investigación forense inicial para determinar alcance
3. **Hora 4-12:** Cerrar la vulnerabilidad
4. **Hora 12-24:** Evaluar qué datos fueron accedidos

10.4.3 Notificación (72 horas)

A la autoridad de protección de datos (AEPD):

Notificación obligatoria dentro de 72 horas incluyendo:

- Naturaleza de la brecha
- Categorías de datos afectados
- Número aproximado de afectados

- Medidas adoptadas

A los usuarios afectados:

Si el incidente implica alto riesgo para derechos y libertades:

Asunto: Importante - Incidente de seguridad

Estimado usuario,

El [fecha], detectamos un acceso no autorizado a nuestros sistemas

que pudo haber comprometido algunos de tus datos.

Datos potencialmente afectados:

- Datos de transacciones en apps (importes, fechas)

- Puntuación crediticia calculada

Datos NO afectados:

- No almacenamos contraseñas

- No almacenamos datos bancarios

Medidas que hemos tomado:

[...]

Medidas que recomendamos:

[...]

Más información y recursos: [link]

10.4.4 Remediación y lecciones aprendidas

Tras resolver el incidente:

- Post-mortem público (versión resumida)
- Auditoría externa de seguridad
- Implementación de mejoras
- Compensación a afectados si procede

11. MEDICIÓN Y CONTROL DEL MODELO DE DATOS MEJORADO

11.1 Métricas operativas en producción

Una vez el sistema esté en producción sirviendo solicitudes reales, monitorizaremos constantemente su comportamiento mediante un dashboard de métricas críticas.

11.1.1 Métricas de volumen y disponibilidad

Requests por segundo (RPS):

- Objetivo: Soportar hasta 100 RPS en picos
- Alarma si RPS supera 80 de manera sostenida (indica necesidad de escalar)

Latencia percentiles:

p50 (mediana): < 30ms

p95: < 50ms

p99: < 100ms

p99.9: < 200ms

Si p95 supera 50ms durante 5 minutos consecutivos, escalar horizontalmente añadiendo contenedores.

Tasa de errores:

Errores 4xx (cliente): < 2% (típicamente validaciones fallidas)

Errores 5xx (servidor): < 0.1% (errores nuestros)

Cualquier error 5xx genera alerta inmediata al equipo de guardia.

Disponibilidad (uptime):

- Objetivo: 99.9% mensual (permite ~43 minutos de downtime al mes)

- Medido mediante health checks cada 30 segundos desde múltiples regiones geográficas

11.1.2 Métricas de modelo (ML performance)

Distribución de predictions:

Monitorizamos cómo se distribuyen las predicciones diarias:

Esperado (basado en training):

- Low risk: 30% ± 5%

- Medium risk: 50% ± 5%

- High risk: 20% ± 5%

Si las distribuciones se desvían significativamente, podría indicar:

- Cambio en el perfil de usuarios (drift poblacional)

- Problema con el modelo

- Manipulación/fraude

Prediction confidence:

El modelo no solo predice una clase, también indica su nivel de confianza. Monitorizamos:

Porcentaje de predictions con confianza alta (>80%): Objetivo >60%

Porcentaje de predictions con confianza baja (<50%): Objetivo <15%

Muchas predictions de baja confianza sugieren que el modelo

encuentra usuarios muy diferentes a los del training set.

Calibración continua:

Cada mes, tomamos una muestra de usuarios scoreados y verificamos outcomes reales:

Ejemplo mes de Febrero 2026:

Usuarios predichos como Low Risk (score >700):

- Total: 1,200

- Con outcomes conocidos tras 6 meses: 450

- Defaults observados: 32

- Tasa de default real: 7.1%

Tasa esperada según modelo: 5-8%

Conclusión: Modelo bien calibrado ✓

11.2 Detección de drift (degradación del modelo)

Los modelos de ML se degradan con el tiempo porque el mundo cambia. Implementamos múltiples mecanismos de detección temprana.

11.2.1 Data drift (cambios en los datos de entrada)

Monitorizamos si las distribuciones de las features han cambiado:

python

```
# Test Kolmogorov-Smirnov para detectar cambios de distribución

from scipy import stats


for feature in features_list:

    # Comparar distribución actual vs. training

    stat, p_value = stats.ks_2samp(

        training_distribution[feature],

        production_distribution[feature]

    )


    if p_value < 0.05:

        ALERTA: f"Feature {feature} ha cambiado significativamente"
```

Ejemplo real:

Alerta: glovo_avg_ticket ha cambiado significativamente

Training (2024): media=22.50€, std=8.30€

Producción (2026): media=26.80€, std=9.10€

Causa probable: Inflación + cambio de precios en Glovo

Acción: Reentrenar modelo con datos más recientes

11.2.2 Concept drift (cambios en la relación entre features y target)

Aunque las features no cambien, la relación entre ellas y el riesgo puede evolucionar.

Monitorizamos mediante "champions vs challengers":

Mantenemos 3 modelos activos simultáneamente:

1. CHAMPION (modelo en producción actual)
2. CHALLENGER 1 (reentrenado con datos de últimos 6 meses)
3. CHALLENGER 2 (arquitectura alternativa)

Cada solicitud se evalúa con los 3 modelos (solo devolvemos resultado del champion).

Mensualmente comparamos accuracy de los 3 en subset validado:

Si CHALLENGER supera a CHAMPION por >2% durante 2 meses consecutivos:

→ Promover CHALLENGER a CHAMPION

11.2.3 Alertas de anomalías

Detectamos patrones anómalos que podrían indicar problemas:

Spike en rechazos:

Si tasa de high-risk supera 30% en cualquier período de 4 horas:

→ Alerta: "Posible problema con fuente de datos o ataque de fraude masivo"

Cambio abrupto en feature importance:

Si la importancia relativa de features cambia >20% súbitamente:

→ Alerta: "Posible problema con pipeline de feature engineering"

Usuarios idénticos:

Si detectamos >5 usuarios con features 100% idénticas:

→ Alerta: "Posible fraude coordinado o bug en generación de datos"

11.3 Testing continuo y A/B testing

11.3.1 Shadow mode testing

Antes de desplegar cambios significativos en el modelo, los ejecutamos en "shadow mode":

Arquitectura:

Solicitud → [Modelo Actual (responde al cliente)]

↘ [Modelo Nuevo (calcula pero no responde)]

Registramos ambas predicciones.

Tras 2 semanas de shadow mode, comparamos:

- ¿El modelo nuevo clasifica igual que el actual?
- ¿Hay casos donde difieren significativamente?
- Cuando difieren, ¿cuál parece más acertado?

Solo si el modelo nuevo pasa todas las validaciones → Deployment

11.3.2 A/B testing para mejoras incrementales

Para cambios menores (nuevas features, ajustes de hiperparámetros), usamos A/B testing:

10% del tráfico → Variante B (con cambio)

90% del tráfico → Variante A (control)

Monitorizamos durante 4 semanas:

Métricas primarias:

- Accuracy en casos con outcomes conocidos

- Latencia de respuesta

- Satisfacción de cliente fintech

Si B > A de manera estadísticamente significativa:

→ Gradual rollout al 100%

Si B ≈ A o B < A:

→ Descartar cambio

11.4 Feedback loops y mejora continua

El verdadero valor viene de cerrar el loop: usar outcomes reales para mejorar el modelo.

1.4.1 Captura de outcomes reales

Acuerdos con fintech clientes para recibir feedback:

Cuando fintech aprueba un préstamo basado en nuestro scoring:

Mes 0: Aprobación

Mes 1-6: Fintech monitoriza pagos

Mes 6: Fintech envía outcome final

```
POST /feedback/outcome

{

  "user_id_hash": "abc123...",  // Pseudonimizado
```

```
  "score_id": "score_789",
  "score_given": 718,
  "approved": true,
  "loan_amount": 3000,
  "outcome": "good_payer",  // Options: good_payer, late_payer, default
  "months_tracked": 6
}
```

Este feedback se acumula en una base de datos de "ground truth" etiquetada.

11.4.2 Reentrenamiento programado

Pipeline automatizado de reentrenamiento:

yaml

Schedule: Mensual (primer domingo de cada mes, 2 AM)

Pasos:

1. Extraer nuevos datos:
   - Outcomes reales recibidos último mes
   - Datos frescos de usuarios activos

2. Combinar con datos históricos:
   - Mantener ventana móvil de 12 meses
   - Desechar datos >12 meses

3. Reentrenar modelo:
   - Mismo algoritmo (XGBoost)
   - Re-optimizar hiperparámetros via grid search

4. Validar modelo nuevo:

   - Cross-validation

   - Comparar con modelo actual en hold-out set

5. Deploy si supera threshold:

   - Si accuracy > actual + 1%: Deploy automático

   - Si accuracy ≈ actual: Mantener actual

   - Si accuracy < actual: Alerta para investigación manual

11.4.3 Active learning

Para casos donde el modelo tiene baja confianza, solicitamos validación humana preferentemente:

Si confidence < 50%:

→ Marcar para "review manual" por parte de la fintech

→ Capturar decisión humana

→ Usar estos casos difíciles para reentrenamiento

  (tienen mayor valor informativo que casos obvios)

Esta estrategia maximiza el valor de cada etiqueta humana, focalizando esfuerzo en los casos más informativos.

11.5 Documentación y governance

11.5.1 Model cards (tarjetas de modelo)

Mantenemos documentación exhaustiva del modelo siguiendo el framework de Model Cards (Google):

markdown

Model Card: Scoring Crediticio Alternativo v2.3

Detalles del modelo

Desarrollador: [Empresa]

- Fecha entrenamiento: 2025-01-15
- Versión: 2.3
- Algoritmo: XGBoost
- Framework: scikit-learn 1.4.0

Uso previsto

- Evaluación de riesgo crediticio para personas sin historial bancario
- Complemento a scoring tradicional, NO reemplazo completo
- Mercado: España (es-ES)

Factores relevantes

- Edad: 18-65 años
- Datos de consumo digital de últimos 6 meses mínimo

Métricas de rendimiento

- Accuracy: 78.5% [76.2%-80.9% IC95%]
- AUC-ROC: 90.2%
- Evaluado en dataset de 1,000 usuarios (80/20 split)

Datos de entrenamiento

- 1,000 usuarios sintéticos (limitación conocida)
- Próximo reentrenamiento usará datos reales
- Distribución: 30% low risk, 50% medium, 20% high

Análisis de equidad

- Disparate impact ratio: >0.85 para todos los grupos etarios ✓
- Sin diferencias significativas por género
- Requiere validación con datos reales

Limitaciones conocidas

- Usuarios <30 días de historial: predicciones menos confiables
- Autónomos: mayor error rate
- No detecta fraude sofisticado

Recomendaciones de uso

- Umbral recomendado aprobación automática: score >750
- Rango 650-750: Review manual
- Rango <650: Rechazar o solicitar garantías adicionales

Contacto

- Equipo: ml-team@[empresa].com
- DPO: dpo@[empresa].com

11.5.2 Registro de cambios (changelog)

Toda modificación del modelo se documenta:

v2.3 (2025-01-15)

Added

- Feature: spending_trend (tendencia de gasto últimos 6 meses)
- Feature: cabify_late_night_ratio

Changed

- Incrementado peso de movistar_punctuality de 6% a 8%
- Threshold de high_volatility_flag ajustado de 0.5 a 0.6

Performance

- Accuracy: 78.5% (+1.2% vs v2.2)
- Latencia p95: 42ms (-3ms vs v2.2)

Migration notes

- Requiere recalculo de scores para usuarios existentes
- Compatible con API v2.x

11.5.3 Comité de validación de modelos

Para cambios mayores (nueva arquitectura, nuevas fuentes de datos), requerimos aprobación de comité:

Composición:

- CTO

- ML Lead

- 1 representante de cliente clave

- Asesor externo (rotatorio)

Criterios de aprobación:

- Mejora demostrable de métricas (>2%)

- Sin degradación de fairness

- Impacto en latencia aceptable

- Documentación completa

12. CRONOGRAMA Y MÉTRICAS DE ÉXITO

12.1 Cronograma de implementación (18 meses)

Estructuramos el proyecto en seis fases principales con hitos medibles en cada una.

12.1.1 Fase 1: Constitución y desarrollo MVP (Meses 1-4)

Mes 1 - Constitución legal y setup inicial:

- Semana 1-2: Constitución de sociedad, apertura de cuenta bancaria, registro mercantil

- Semana 3: Firma de acuerdos entre fundadores, distribución de equity

- Semana 4: Setup de infraestructura básica (AWS account, GitHub organization, herramientas)

Hito: Sociedad constituida, equipo con acceso a herramientas

Mes 2 - Desarrollo del core del modelo:

- Semana 1-2: Generación de dataset sintético a mayor escala (10.000 usuarios)

- Semana 3: Feature engineering y pipeline de preprocessing

- Semana 4: Entrenamiento de modelos baseline

Hito: Modelo funcional en notebook

Mes 3 - Desarrollo de API:

- Semana 1-2: Implementación de API REST con FastAPI

- Semana 3: Testing, documentación, containerización con Docker

- Semana 4: Deploy en AWS, configuración CI/CD

Hito: API funcionando en staging

Mes 4 - Refinamiento y preparación:

- Semana 1-2: Optimización de performance, caching

- Semana 3: Preparación de materiales comerciales (pitch deck, one-pager, demos)

- Semana 4: Primeros acercamientos a potenciales clientes

Hito: Sistema completo listo para piloto

Métrica de éxito Fase 1: MVP funcional con latencia <100ms y 2-3 fintech interesadas en piloto

12.1.2 Fase 2: Pilotos con primeros clientes (Meses 5-8)

Mes 5 - Onboarding de pilotos:

- Selección de 2-3 fintech para piloto gratuito de 90 días
- Integración técnica (típicamente 1-2 semanas por cliente)
- Configuración de acceso, claves API, documentación personalizada

Hito: 2-3 clientes en piloto activo

Mes 6-7 - Ejecución de pilotos:

- Soporte intensivo a clientes piloto
- Recolección de feedback semanal
- Ajustes iterativos del modelo basados en casos reales
- Monitorización de métricas de uso

Hito: 500+ consultas reales procesadas

Mes 8 - Evaluación y cierre de pilotos:

- Análisis de resultados con cada cliente
- Preparación de casos de estudio

- Conversión a clientes de pago (objetivo: 2 de 3 convierten)

Hito: 2 primeros clientes de pago firmados

Métrica de éxito Fase 2: Al menos 2 clientes pagando, >60% satisfaction score en surveys

12.1.3 Fase 3: Escala inicial (Meses 9-12)

Mes 9 - Contratación y scaling:

- Incorporación de Sales/BD Representative

- Incremento de capacidad de infraestructura cloud

- Automatización de procesos de onboarding

Hito: Equipo expandido a 5 personas

Mes 10-11 - Adquisición activa:

- Pipeline de prospección activa (objetivo: 20 leads cualificados)

- Participación en South Summit / FinnoSummit

- Publicación de primer caso de estudio

Hito 5-7 clientes totales

Mes 12 - Cierre de año 1:

- Reentrenamiento del modelo con datos reales acumulados

- Preparación de report anual para inversores

- Planificación de año 2

Hito: 7-8 clientes, ingresos recurrentes >5.000€/mes

Métrica de éxito Fase 3: 7+ clientes activos, MRR >5.000€, churn rate <10%

12.1.4 Fase 4: Consolidación y mejora de producto (Meses 13-15)

Mes 13 - Incorporación de nuevas fuentes:

- Negociación con proveedores de utilities (Iberdrola, etc.)

- Desarrollo de conectores adicionales

- Testing de modelos con features expandidas

Hito: 2-3 fuentes de datos adicionales integradas

Mes 14 - Desarrollo de features premium:

- Dashboard analítico para clientes

- Webhooks para notificaciones en tiempo real

- API de consulta batch para grandes volúmenes

Hito: Features premium lanzadas

Mes 15 - Optimización operativa:

- Automatización de customer success

- Mejoras de performance (reducir latencia a <30ms p95)

- Implementación de A/B testing framework

Hito: Sistema optimizado, latencia reducida 30%

Métrica de éxito Fase 4: 12+ clientes, features premium adoptadas por 50%+ clientes

12.1.5 Fase 5: Expansión acelerada (Meses 16-18)

Mes 16 - Expansión del equipo:

- Incorporación de Customer Success Manager

- DevOps Engineer para escalabilidad

- Data Engineer para pipelines avanzados

Hito: Equipo de 8 personas

Mes 17 - Entrada en segmento enterprise:

- Conversaciones con neobancos (N26, Revolut)
- Desarrollo de SLAs customizados
- Implementación de high-availability (99.95% uptime)

Hito: 1-2 clientes enterprise en pipeline

Mes 18 - Preparación Serie A:

- Cierre del año financiero
- Métricas consolidadas para inversores
- Roadmap detallado para siguientes 24 meses
- Preparación de data room

Hito: Documentación completa para fundraising

Métrica de éxito Fase 5: 20+ clientes, MRR >25.000€, 1+ cliente enterprise firmado

12.1.6 Fase 6: Preparación de siguiente etapa (Mes 18+)

Objetivos post-mes 18:

- Ronda Serie A (1.5M-2.5M€)
- Expansión a Portugal como primer mercado internacional
- Equipo objetivo: 15 personas para fin de año 2
- MRR objetivo fin año 2: 80.000€

12.2 Métricas clave de éxito (KPIs)

Definimos métricas específicas agrupadas por categoría que monitorizaremos mensualmente.

12.2.1 Métricas de producto

Performance técnica:

Latencia p95: <50ms (target), <30ms (aspiracional)

Uptime: >99.9% mensual

Error rate 5xx: <0.1%

Throughput máximo: 100 RPS sin degradación

Calidad del modelo:

Accuracy (validado): >75% (mínimo), >80% (target)

AUC-ROC: >88%

Calibration error: <5%

Data drift alerts/mes: <2

Cobertura:

% usuarios evaluables: >60% de los sin-historial tradicional

% predicciones alta confianza: >65%

12.2.2 Métricas comerciales

Adquisición:

Leads cualificados/mes: Mes 1-6: 5 | Mes 7-12: 15 | Mes 13-18: 25

Conversion rate leads→piloto: >30%

Conversion rate piloto→pago: >60%

Retención:

Churn mensual: <3%

Net Revenue Retention: >110% anual

Expansion revenue: >20% del revenue nuevo

Growth:

Mes 6: 2 clientes pagando

Mes 12: 7-8 clientes

Mes 18: 20+ clientes

Mes 24: 40+ clientes (proyección)

12.2.3 Métricas financieras

Revenue:

MRR Mes 6: ~1.500€

MRR Mes 12: ~6.000€

MRR Mes 18: ~25.000€

ARR Mes 18: ~300.000€

Unit economics:

CAC (Customer Acquisition Cost): <3.000€

LTV (Lifetime Value): >18.000€ (año 3)

LTV/CAC ratio: >6:1

Gross Margin: >75%

Burn rate y runway:

Burn mensual promedio: ~20.000€ (meses 1-12)

~35.000€ (meses 13-18)

Runway con 450k€ inicial: 18+ meses hasta break-even o Serie A

12.2.4 Métricas de satisfacción

Net Promoter Score (NPS):

Survey trimestral a clientes:

Target: NPS >50 (considerado excelente en B2B SaaS)

Pregunta: "¿Qué probabilidad hay de que recomiendes

nuestro servicio a otra fintech?" (0-10 scale)

Promoters (9-10): >60%

Passives (7-8): <30%

Detractors (0-6): <10%

Customer Satisfaction Score (CSAT):

Medido tras cada interacción de soporte:

Target: >4.5/5.0

Dimensiones evaluadas:

- Rapidez de respuesta

- Claridad de explicación

- Resolución del problema

Customer Effort Score (CES):

"¿Qué tan fácil fue integrar nuestro servicio?"

Target: <2.0/7.0 (menor es mejor)

Integration time promedio: <1 semana

12.3 Hitos críticos (go/no-go decision points)

Establecemos checkpoints donde evaluaremos si continuar, pivotar, o cerrar.

12.3.1 Checkpoint Mes 6

Criterios mínimos para continuar:

- ✓ MVP técnicamente funcional (latencia <100ms, uptime >99%)
- ✓ Al menos 2 clientes piloto completados
- ✓ Al menos 1 cliente convierte a pago
- ✓ Feedback positivo (NPS >30)

Si NO se cumplen:

- Analizar por qué los pilotos no convirtieron
- Considerar pivot en propuesta de valor
- Evaluar si el timing de mercado es correcto

Decisión: Continuar con plan / Pivotar estrategia / Cerrar

12.3.2 Checkpoint Mes 12

Criterios mínimos:

- ✓ 5+ clientes de pago activos
- ✓ MRR >4.000€
- ✓ Churn mensual <5%
- ✓ Modelo validado con datos reales (accuracy >75%)
- ✓ LTV/CAC ratio >3:1

Si NO se cumplen:

- ¿Es problema de producto (no resuelve el dolor)?
- ¿Es problema de go-to-market (no llegamos al cliente correcto)?
- ¿Es problema de timing (mercado no listo)?

Decisión: Continuar a Fase 3 / Ajustar estrategia / Considerar cierre ordenado

12.3.3 Checkpoint Mes 18

Criterios para Serie A:

- ✓ 15+ clientes de pago
- ✓ MRR >20.000€ con crecimiento >15% mensual
- ✓ Net Revenue Retention >100%
- ✓ Unit economics saludables (LTV/CAC >5:1)
- ✓ Runway suficiente (6+ meses) o path claro a profitabilidad

Opciones en este punto:

1. **Serie A agresiva:** Si growth es fuerte, levantar 2-3M€ para acelerar
2. **Crecimiento orgánico:** Si métricas son buenas pero no espectaculares, continuar con capital actual hacia profitabilidad
3. **Venta estratégica:** Si recibimos oferta interesante de adquisición
4. **Wind down:** Si no hemos encontrado product-market fit

12.4 Roadmap de producto futuro

Más allá del horizonte de 18 meses, visualizamos evolución del producto:

12.4.1 Año 2 (Meses 19-30)

Q1-Q2:

- Lanzamiento en Portugal (primer mercado internacional)
- Modelos especializados por segmento (jóvenes, autónomos, inmigrantes)
- Integration con plataformas de open banking (Tink, Plaid)

Q3-Q4:

- Desarrollo de scoring en tiempo real (streaming, no batch)
- API de pre-aprobación instantánea para e-commerce
- Dashboard predictivo (proyecciones de riesgo a 6-12 meses)

12.4.2 Año 3 (Meses 31-42)

Expansión geográfica:

- Italia, Francia (mercados similares a España)
- México, Colombia (LATAM de habla hispana)

Nuevos productos:

- Credit monitoring subscription para consumidores finales (B2C)
- Fraud detection como servicio adicional
- Marketplace de servicios financieros (conectar fintech con usuarios)

Tecnología:

- ML models con deep learning
- Graph neural networks para detección de fraude en redes
- AutoML para optimización continua sin intervención humana

16. Bibliografía y Referencias

Amazon Web Services. (2025). *AWS for Financial Services: Driving innovation in banking, payments, and capital markets*. https://aws.amazon.com/financial-services/

Amazon Web Services. (2026). *AWS Activate: Cloud Credits and Resources for Your Startup*. https://aws.amazon.com/activate/

Belvo. (s.f.). *Plans and pricing*. Recuperado el 28 de enero de 2026, de https://belvo.com/plans-and-pricing/

Bessemer Venture Partners. (2024). *State of the Cloud 2024: The New Era of Efficiency*. https://www.bvp.com/atlas/state-of-the-cloud-2024

Cleveroad. (2025, 1 de diciembre). *FinTech App Development Cost: Detailed Estimation for 2026*. https://www.cleveroad.com/blog/fintech-app-development-cost/

Enisa. (2026). *Líneas de Financiación: Jóvenes Emprendedores*. Empresa Nacional de Innovación S.A. https://www.enisa.es/es/financia-tu-empresa/lineas-de-financiacion/d/jovenes-emprendedores

FICO. (2023). *FICO® Score 10 and 10 T: The next generation of credit risk innovation [Technical White Paper]*. Fair Isaac Corporation. https://www.fico.com/en/latest-thinking/white-paper/fico-score-10-and-10-t-technical-white-paper

GetApp. (2025). *RiskSeal 2025 Pricing, Features, Reviews & Alternatives*. https://www.getapp.com/security-software/a/riskseal/

Khandani, A. E., Kim, A. J., & Lo, A. W. (2010). Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance*, *34*(11), 2767–2787. https://doi.org/10.1016/j.jbankfin.2010.06.001

Meritech Capital. (2025). *SaaS Public Company Revenue Multiples and Margins*. https://www.meritechcapital.com/state-of-the-cloud

Siddiqi, N. (2017). *Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards* (2nd ed.). John Wiley & Sons.

South Summit. (2026). *Startup Competition 2026: Visibility, Investments and New Clients*. https://www.southsummit.io/e/madrid/content/startup-competition-2026

Stack Overflow. (2025, mayo). *2025 Developer Survey: Cloud platforms and infrastructure trends*. https://survey.stackoverflow.co/2025/

Techjockey. (2026). *Provenir Pricing & Reviews 2026*. https://www.techjockey.com/detail/provenir

Thomas, L. C. (2017). *Consumer Credit Models: Pricing, Profit and Portfolios*. Oxford University Press.

VantageScore. (2024). *VantageScore 4.0: Model Performance and Consistency Report*. VantageScore Solutions, LLC. https://www.vantagescore.com/resource/vantagescore-4-0-performance-report/